

武汉大学

本科毕业论文（设计）

基于视频编码的协处理方案

姓 名：	罗子聪
学 号：	2022302121310
专 业：	通信工程
学 院：	电子信息学院
指导教师：	黄公平

二〇二六年四月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：	指导教师签名：
日 期：	年 月 日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：	指导教师签名：
日 期：	年 月 日

摘要

尽管 NVENC 等硬件编码器具有极低延迟和高吞吐量的优势，但在低码率工况下面临严重的感知质量下降问题，块效应、振铃效应和纹理模糊限制了其在直播推流、云游戏等实时场景中的应用。与此同时，学术界主流的深度学习增强模型，如基于 Transformer 的图像超分和去噪模型，虽然在复原指标上表现较强，但其参数量动辄达数千万、推理时延高达数百毫秒，使其无法嵌入实时编码流水线。

针对上述问题，本文提出了一种基于强化学习的视频编码协处理方案。该方案以 NVENC 硬件编码器为核心，通过引入轻量级码率自适应前处理网络 (RAP-Net) 实现编码前的智能视频增强。系统基于 Actor-Critic 架构，采用残差学习策略将动作空间约束为对原始帧的微调修正，并设计了基于相对率失真增益的复合奖励函数，在感知质量与传输码率之间进行权衡。此外，提出了包含加权 MSE 损失、非边缘高频抑制损失和全变分平滑损失的频域感知复合损失策略，用于抑制增强过程中的高频伪影。

实验在 1080p 分辨率、YUV420 格式的 5 个 UVG 测试序列上进行。在本文实验设置下，RAPNet 以平均前处理开销 5.4ms/帧（约占端到端时延 12%）、参数量 113K 的代价，获得平均 -9.48% 的 BD-LPIPS 收益；其中 ParkScene 和 BasketballDrive 分别达到 -13.45% 和 -12.84%。这些结果表明，在 NVENC 实时编码流水线中引入轻量前处理后，可以在维持毫秒级额外时延的同时，降低低码率场景下的感知率失真代价。

关键词：视频编码；硬件编码器；强化学习；前处理；率失真优化

ABSTRACT

Although hardware encoders like NVENC offer extremely low latency and high throughput, severe perceptual quality degradation—including blocking artifacts, ringing, and texture blurring—at low bitrates limits their application in real-time scenarios such as live streaming and cloud gaming. Meanwhile, mainstream deep learning enhancement models, despite their strong perceptual restoration performance, typically require tens of millions of parameters and hundreds of milliseconds of inference time, making them impractical for real-time encoding pipelines.

To address these issues, this thesis proposes a reinforcement learning-based video coding co-processing solution. Using the NVENC hardware encoder as the baseline, the system introduces a lightweight Rate-Adaptive Pre-processing Network (RAPNet) for intelligent video enhancement prior to encoding. Based on the Actor-Critic framework, the system employs a residual learning strategy to constrain the action space to fine-grained frame-level corrections, and designs a compound reward function formulated on relative rate-distortion gain to balance perceptual quality and transmission bitrate. Furthermore, a frequency-aware composite loss strategy—comprising weighted MSE loss, non-edge high-frequency suppression loss, and total variation smoothing loss—is proposed to suppress high-frequency artifacts introduced during enhancement.

Comprehensive experiments on five UVG 1080p sequences validate the approach. Under the experimental setup described in this thesis, the proposed RAPNet achieves an average BD-LPIPS gain of -9.48% with only 113K parameters and an average pre-processing overhead of 5.4 ms per frame, accounting for approximately 12% of the end-to-end latency. These results demonstrate that introducing lightweight pre-processing into an NVENC-based real-time encoding pipeline can effectively reduce the perceptual rate-distortion cost while maintaining only millisecond-level additional latency.

Keywords: Video Coding; Hardware Encoder; Reinforcement Learning; Pre-processing; Rate-Distortion Optimization

目 录

摘要	I
ABSTRACT	II
符号表	VII
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.3 研究内容与主要工作	3
1.4 本文创新点	4
1.5 论文结构安排	4
2 相关工作与理论基础	6
2.1 视频编码标准演进	6
2.1.1 H.265/HEVC 标准	6
2.1.2 H.266/VVC 标准	6
2.1.3 硬件编码器 NVENC 与基本编码框架	7
2.2 前处理技术分析	8
2.2.1 编码器感知前处理的发展脉络	8
2.2.2 面向实时编码的模型选型	9
2.3 后处理技术分析	12
2.4 强化学习基础	13
2.5 本章小结	14
3 系统设计与实现	15
3.1 系统架构与设计思路	15
3.1.1 Actor-Critic 反馈闭环	16
3.2 前处理优化的设计与训练算法	18
3.2.1 状态、动作与训练样本构建	18
3.2.2 奖励机制与损失函数	20
3.3 模块实现与技术细节	21
3.3.1 Actor-Critic 网络实现	21
3.3.2 编码环境与训练流程	23

3.4	本章小结	26
4	实验与结果分析	28
4.1	实验环境与评价体系	28
4.2	综合率失真性能与效率分析	30
4.3	强化学习训练演进与案例诊断	32
4.4	增强机理与主观效果解释	34
4.5	系统消融实验与参数寻优	36
4.6	本章小结	39
5	总结与展望	41
5.1	工作总结	41
5.2	研究局限性与讨论	41
5.3	未来工作展望	42
	参考文献	44
	致谢	49
	附录 A 关键实现说明	50
A1	RAPNet (Actor) 详细网络结构	50
A2	ValueNet (Critic) 详细网络结构	50
A3	损失权重与训练超参数	51
A4	FFmpeg 编码/解码命令示例	52
A5	核心代码文件目录说明	53
	附录 B 代码提交说明	54

插图

1.1 NVENC H.265 低码率编码重建帧对比 (QP=45; 两帧均为编码后 解码重建帧)	2
2.1 I/P/B 帧类型与 GOP 结构示意图	7
3.1 总体前处理流程图	16
3.2 整体强化学习框架示意图	18
3.3 基于 Actor-Critic 架构的视频前处理优化系统框图	22
3.4 代码训练流程总览	25
4.1 Baseline 与 RAPNet 平均 RD 曲线对比 (LPIPS vs 码率)	31
4.2 TensorBoard 训练监控曲线	33
4.3 训练过程中的典型失败案例	33
4.4 训练过程中图片频域变化	34
4.5 模型处理前后频谱差异图 (Spectral Log-Diff)	35
4.6 Baseline 与 RAPNet 彩色主观对比图 (NVENC H.265 编码后重建 帧, Zoom 区域为差异最显著的局部放大)	35
4.7 Y/Cb/Cr 各通道编码重建帧对比与差异图 (差异图以 99 百分位归 一化; 暖色表示 RAPNet 增亮, 冷色表示减暗)	36
4.8 NVENC 编码预设对比实验 (HEVC-NVENC, 96 帧, 1x Scale)	37
4.9 不同 GOP 配置下的下采样算法 RD 曲线对比	38
4.10 不同下采样倍数下的 Y-PSNR 对比 (Preset: p1, GOP: Default)	38

表 格

2.1	主流视频编码标准对比, 整理自文献 ^[21]	6
2.2	FFmpeg 硬件加速核心组件	7
2.3	离线去噪大模型客观指标综合对比 (PSNR, 彩色高斯去噪 $\sigma = 15$)	9
2.4	编码器感知前处理方法对比表	9
2.5	视频超分辨率模型性能对比 (PSNR(dB)/SSIM), 数据整理自文献 ^[6]	11
2.6	主流模型参数与效率对比 (320×180 输入), 数据整理自文献 ^[6]	11
2.7	主流轻量级模型参数与效率对比, 数据整理自文献 ^[38]	12
2.8	主流模型复杂度与性能综合对比	12
3.1	NVENC 编码环境参数配置	25
4.1	实验硬件环境配置	28
4.2	实验软件环境配置	28
4.3	测试视频序列	29
4.4	实验评价指标	29
4.5	RAPNet 前处理框架测试结果	30
4.6	模型效率对比 (输入分辨率: 960×540 , GPU: RTX 4090; 推理时间为重复测量后的平均单帧耗时)	31
4.7	编码流水线各阶段时延分解 (960×540 , 单位: ms/帧; 结果为重复测量后的平均值)	31
4.8	损失函数消融实验结果 (5 序列平均 BD-LPIPS, %)	39
4.9	训练策略对比与机制分析	39
A.1	RAPNet (Actor) 网络结构详情 (scale = 2 时, $C_{in} = 3 \times 2^2 = 12$)	50
A.2	ValueNet (Critic) 网络结构详情	51
A.3	训练主要超参数配置	51

符号表

s_t	t 时刻的状态，表示当前输入视频片段
a_t	t 时刻的动作，表示前处理后的输出帧
$r_t^{(q)}$	在量化参数 q 下的单 QP 奖励
$\bar{r}_t$	跨 QP 点平均奖励
V_{cur}	当前动作经编码后的感知质量分数
R_{cur}	当前动作经编码后的实际码率
V_{ref}	基准编码器的参考感知质量分数
R_{ref}	基准编码器的参考码率值
$\Delta V_t^{(q)}$	在量化参数 q 下的感知质量增益
$\Delta R_t^{(q)}$	在量化参数 q 下的相对码率变化
π_θ	Actor 策略函数
Q_ϕ	Critic 价值函数
α	感知质量增益权重系数
β	码率节省权重系数
γ	折扣因子
$\mathcal{Q}$	训练与测试使用的 QP 集合
w_{mse}	加权 MSE 损失权重
w_{hf}	非边缘高频抑制损失权重
w_{TV}	全变分平滑损失权重
LPIPS	学习感知图像块相似度指标
BD-LPIPS	以 LPIPS 为质量轴计算的 Bjontegaard Delta 码率指标
SSIM	结构相似性指标
PSNR	峰值信噪比
BD-Rate	Bjontegaard Delta Rate
QP	量化参数

1 绪论

1.1 研究背景与意义

随着 5G 通信与流媒体技术的蓬勃发展，视频数据已成为全球互联网流量的主体，占比超过 80%。在实时视频通话、云游戏、远程办公与 AR/VR 等新兴场景中，用户不仅要求超低时延，还要求在有限带宽下获得高质量的视觉体验。然而，传统视频编码标准在面对这一需求时正面临严峻挑战。首先，H.264/AVC 凭借其极高的兼容性虽然商用最为广泛，但在面对高清 (1080P 及以上) 视频时，其压缩效率已显疲态，难以在低带宽下维持画质。其次，H.265/HEVC 虽然在同等画质下能节省约 50% 的码率，但其碎片化的专利池与复杂的授权政策严重阻碍了其全面普及^[1]。再者，H.266/VVC 虽然率失真性能强大^[2]，但其编码计算复杂度相比 H.265 激增了数倍至数十倍，极高的编码时延难以满足端侧设备对实时交互的严苛要求。

与此同时，端到端深度学习编码方案虽然性能卓越，但受限于巨大的算力开销和功耗，难以在边缘设备上部署^[3]。此外，现有深度学习编码工具多针对传统编码框架的局部模块进行优化，缺乏对整体编码过程的感知，通常需要多阶段迭代训练以获得性能提升^[4]。

图 1.1 以 NVENC 硬件编码器在 QP=45 低码率工况下的重建帧为例，直观展示了上述画质问题：平坦水面区域出现可见的块状纹理（块效应），礁石边缘处亦伴随振铃与细节模糊。这正是本文所要解决的核心工程问题。右侧为本文方案（RAPNet 前处理后编码）的重建结果，可以看到相同 QP 下感知质量已有明显改善。

面对现有视频编码标准在低码率场景中的质量瓶颈，尽管学术界提出了多种视频画质增强方案，如基于深度学习的超分辨率模型和去噪模型，但这些方案在实时流媒体和云游戏等工程场景中的应用面临困难。一方面，传统的画质增强算法多依赖手工设计的低通滤波器，虽然能滤除高频噪声、降低码率，但缺乏对图像内容自感知的能力，容易导致画面过度平滑；另一方面，学术界主流的深度学习的增强模型，如基于 Transformer 的架构^[5-6]，凭借庞大的参数量在客观指标上取得较高结果，但其极高的计算复杂度使其只能作为离线后处理方案，无法满足流媒体实时场景的时延约束。更为关键的是，陈彤等人在综述^[7]中指出，




图 1.1 NVENC H.265 低码率编码重建帧对比（QP=45；两帧均为编码后解码重建帧）

当前智能编码的痛点在于学术界过于追求单纯的率失真性能，而忽略了工业界迫切需要的实用性考量，如计算复杂度、跨平台部署难度及极低延迟，这些后处理模型往往无法真实感知硬件编码器底层的压缩特性。相比之下，AI 前处理技术提供了一条更适合工程部署的路径。

相关的深度学习视频编码综述^[4]明确指出，前处理的核心目标是在进入标准编码器之前，通过神经网络去除心理视觉冗余^①。这也是近年工业界优化编码管道的重要实践，正如 bilibili 团队^[8]在 RPP 方案中所采取的策略：通过利用神经网络将对主观视觉影响较小、且编码开销极大的非本质高频信息^②过滤为零，能够直接从源头减少残差能量，进而改善后续硬件编码器的熵编码效率。

本研究正是在此背景下，旨在打破前处理与编码器之间的隔阂，引入一套遵循上述实用性与轻量化约束的 AI 协处理方案——基于强化学习的智能前处理技术。该方案的核心目标是不改动硬件编码器主体，不显著增加额外计算量，而是在真实编码端前对视频进行感知侧的自适应优化。本系统将 NVENC 硬件编码器视为黑盒环境，利用强化学习框架动态调整增强策略。在本文的实验设置下，

① 心理视觉冗余（Psychovisual redundancy）是指人眼视觉系统（HVS）关注不到或不敏感的图像纹理和细节，将其滤除能在不影响主观感受的前提下大幅节省码率开销。

② 在视频编码语境中，此处的高频信息通常指人眼视觉系统不敏感的高频纹理或噪声干扰。适度滤除它们能够大幅减少残差能量，进而提升编码效率，同时基本不影响主观感受。

模型参数量为 113K, 平均前处理时延为 5.4ms/帧, 并在 5 个 1080p 测试序列上取得平均 -9.48% 的 BD-LPIPS 收益, 说明轻量前处理能够直接作用于低码率场景下的感知率失真表现。

1.2 国内外研究现状

过去三十余年, 主流视频编码技术路线始终围绕变换、预测、环路滤波等规则驱动的工具展开精细化设计与协同优化, 并依托 MPEG、AVS、AOM 等标准化组织构建起成熟的生态体系^[2]。尽管 H.266/VVC 等新一代标准的压缩效率持续提升, 但在工业界大规模商用场景中, 受限于极高的计算复杂度、编码时延以及复杂的专利布局, H.264/AVC 与 H.265/HEVC 仍占据着绝对主导地位。

近十年来, 随着深度神经网络的快速发展, 视频编码领域迎来了新的变革^[4]。当前研究已逐渐分化为两条路线: 一条是全 AI 端到端架构, 通过深度网络完全替代传统流程^[3,9-10], 虽然在多个公开数据集上展现出优于 H.265/HEVC 的压缩效率^[1], 但其庞大的算力开销使其难以在边缘设备上部署; 另一条是围绕固定硬件编码器进行前后处理协同的 AI 增强架构^[11-13], 在针对超分辨率^[14]、滤波去噪^[15]、变换^[16]、帧内帧间预测^[17]等环节进行模块化替换或辅助增强。近期也有工作尝试将视频编解码器重新抽象为更通用的张量压缩基础设施^[18], 说明编码技术与 AI 系统之间的边界正在进一步模糊。后一条路线因其部署灵活、兼容 H.26x 标准的优势, 成为当前工业界与学术界的研究热点。

1.3 研究内容与主要工作

本文提出了由硬件编码器、轻量前处理与 AI 后处理构成的视频编码协处理框架。为突出研究对象与技术主线, 本文聚焦于 NVENC 硬件编码链路中的前处理优化问题, 重点研究前处理网络设计、强化学习训练机制及其对率失真性能的影响; 后处理联合优化仅作为整体系统背景, 不在本文中重点展开。基于上述范围界定, 本文的主要工作包括:

(1) **课题研究与方案设计:** 调研分析 H.265 硬件编码 (NVENC) 相较于软件编码的优劣势, 特别是其在低功耗、高效率方面的特点以及可能存在的率失真性能损失问题。研究硬件编码结合轻量前处理的视频编码落地路径, 设计一套兼顾低功耗和率失真性能的混合编码框架;

(2) **系统实现与模型构建:** 搭建实验系统, 集成 NVENC 硬件编码器, 实现基于强化学习的 RAPNet^[19] 前处理算法, AI 算法的模型参数量控制在 1M 以内;

(3) **实验验证与性能评估**：使用 1080p 分辨率、YUV420 格式（NV12 转换）的 UVG 视频序列数据集^[20]，在 CQP 模式下以 $QP \in \{37, 40, 42, 45, 47\}$ 五个测试点进行量化验证，对比 BD-LPIPS 感知率失真收益、主观视觉效果、计算复杂度等指标。

1.4 本文创新点

本文的主要工作与相对改进包括：

(1) **提出面向不可导硬件编码器的前处理优化框架**。针对 NVENC 等闭源硬件编码器不可导、难以与常规端到端训练直接耦合的问题，本文将硬件编码器建模为强化学习环境，将编码实际码率与感知质量作为反馈信号，构建了前处理、编码、评价与更新构成的闭环优化流程，为前处理策略适应编码器特定行为提供了一种可行途径。

(2) **引入轻量化 RAPNet 并构建频域感知复合损失机制**。结合实时编码链路中的可部署性约束，本文引入轻量级的 RAPNet^[19] 作为前处理策略网络；为避免常规下采样导致的高频信息缺失，采用了 Random Crop 训练策略；同时构建了由加权 MSE、非边缘高频抑制与全变分平滑组成的复合损失，以在不同内容与码率条件下约束伪影并稳定训练。

(3) **在实时约束下给出了可部署性的定量结果**。在本文实验设置下，模型参数量为 113K、平均单帧推理时间为 5.4ms，前处理开销约占端到端时延的 12%。对应地，系统在 5 个 1080p 测试序列上取得平均 -9.48% 的 BD-LPIPS 收益，其中 ParkScene 达到 -13.45%。这组结果说明该方案并非仅在离线指标上有效，而是在 NVENC 实时编码链路中给出了可测的复杂度与收益对比。

1.5 论文结构安排

本文共分为五章，各章内容安排如下：

第一章为绪论，介绍研究背景与意义、国内外研究现状概述、研究内容与主要工作、本文创新点以及论文结构安排。

第二章为相关工作与理论基础，系统梳理视频编码标准演进、编码器感知前处理技术发展脉络、后处理技术分析以及强化学习基础理论，并结合模型复杂度与性能分析，明确本文的技术选型依据。

第三章详细阐述系统设计与实现，包括基于 Actor-Critic 架构的视频前处理优化系统的整体设计、状态空间与动作空间的定义、复合奖励函数设计及网络

损失函数建模。

第四章进行实验与结果分析，在多个 **QP** 测试点上对比基线编码与集成增强前处理的评估指标，从 **BD-LPIPS**、主观视觉效果、计算复杂度等多个维度进行量化验证；同时深入剖析了近 50 个版本的强化学习训练迭代过程，总结了通道崩塌、梯度爆炸等典型失败案例及其工程解决方案。

第五章对全文进行总结，客观剖析本方案在指标选取与数据规模等方面面临的研究局限性，并对未来端到端联合优化等进一步工作进行展望。

2 相关工作与理论基础

2.1 视频编码标准演进

视频编码标准的发展经历了多个重要里程碑。从早期的 H.261 到如今的 H.266/VVC，每一代标准都在压缩效率上持续改进^[21]。本节简要回顾视频编码标准的发展脉络及其核心技术特点，并从后续实验所需的角度，对视频编码的基本组织方式作简要说明，为后文硬件编码器配置与实验设置提供背景。表 2.1 对近年来具有代表性的主流视频编码标准进行了横向比较，可用于概括各标准在分辨率支持、压缩效率与关键特性上的差异。

表 2.1 主流视频编码标准对比，整理自文献^[21]

标准	年份	分辨率	压缩率	关键特性
H.264/AVC	2003	最高 4K	高	先进的帧间预测、帧内预测、熵编码，以及良好的网络适配能力
HEVC (H.265)	2013	最高 8K	高于 H.264	并行处理能力更强、块划分更灵活、运动矢量预测精度更高
VP9	2013	最高 4K	高	免版税，适合 Web 视频场景，支持自适应块划分
AV1	2018	最高 10K	高于 VP9	开放免版税、压缩效率更高，适合高分辨率流媒体传输
VVC (H.266)	2020	最高 8K	高于 HEVC	适用范围更广，压缩技术进一步增强，并面向沉浸式媒体场景优化

2.1.1 H.265/HEVC 标准

H.265/HEVC (High Efficiency Video Coding) 由 ITU-T VCEG 和 ISO/IEC MPEG 联合开发，于 2013 年正式发布^[1]。相比 H.264/AVC，HEVC 在同等主观质量下可节省约 50% 的码率。其核心技术改进主要体现在三个方面：引入了灵活的编码树单元 (CTU) 划分结构，最大支持 64×64 像素块，提高了大尺寸块的编码效率；增强了帧内预测模式，支持 35 种角度预测方向，提高了纹理区域的预测精度；改进了环路滤波器，包括去块效应滤波器 (DBF) 和样本自适应偏移 (SAO) 滤波器。这些技术改进使 HEVC 在高清视频压缩场景中取得了更高的编码效率，成为当前工业界应用广泛的编码标准之一。

2.1.2 H.266/VVC 标准

H.266/VVC (Versatile Video Coding) 于 2020 年发布，在 HEVC 的基础上进一步提升了约 30%–50% 的压缩效率^[2]。然而，其编码计算复杂度的激增使其在实

时应用中面临巨大挑战。

2.1.3 硬件编码器 NVENC 与基本编码框架

NVIDIA Video Encoder (NVENC) 是集成在 NVIDIA GPU 中的专用硬件编码引擎。与软件编码器 (如 x265) 相比, NVENC 具有极低的编码延迟, 可支持实时 1080p/4K 编码, 且功耗极低, 不占用 CPU/GPU 通用计算资源。然而, 由于硬件编码器的算法复杂度受芯片面积约束, 其率失真性能可能不及软件编码器的最高质量模式。这一局限性正是本文研究的优化空间——通过 AI 前处理补偿硬件编码器在低码率下的质量损失。

在 H.264/H.265 等标准中, 视频序列通常以 I 帧、P 帧和 B 帧组织: I 帧独立编码, P 帧以前向参考进行预测, B 帧则利用双向参考以提升压缩效率。上述帧类型按照特定顺序组成 GOP (Group of Pictures) 结构, 如图 2.1所示。GOP 长度决定了关键帧插入间隔, 并直接影响压缩效率、随机访问能力与编码时延。由于本文后续实验涉及 GOP 参数对编码结果的影响, 此处仅保留这一简要说明, 作为实验配置分析的基础。




图 2.1 I/P/B 帧类型与 GOP 结构示意图

在工程实践中, FFmpeg 是最通用的音视频处理工具, 它通过集成 NVIDIA 的硬件加速组件来调用 GPU 编解码能力。表 2.2汇总了本文涉及的核心组件及其功能。

表 2.2 FFmpeg 硬件加速核心组件

组件	类型	功能说明
hevc_nvenc	硬件编码器	利用 GPU 上 NVENC 引擎将原始视频帧压缩为 H.265 码流
hevc_cuvid	硬件解码器	利用 GPU 上 NVDEC 引擎将压缩码流解码为原始视频帧
scale_npp	GPU 缩放滤镜	基于 NPP 库实现 GPU 端缩放避免 CPU-GPU 数据拷贝开销

根据编码器和解码器的选择组合，常见的转码方案可分为三类：软解软编（CPU 解码 → CPU 编码，灵活但速度最慢）、软解硬编（CPU 解码 → NVENC 编码，适合已有解码后原始帧的场景）和硬解硬编（CUVID 解码 → NVENC 编码，数据全程驻留显存，速度最快）。本文的训练系统采用软解硬编方案：通过 Python 的 `subprocess` 模块调用 FFmpeg，将 AI 前处理后的原始 YUV 帧直接送入 NVENC 进行 H.265 编码，随后解码获取重建帧用于质量评估。该方案避免了 GPU 显存中的格式转换开销，同时保持了与实际部署场景一致的编码行为。

2.2 前处理技术分析

视频前处理的目标是在编码前优化原始信号，使其更适合压缩^[8]。对于实时视频编码系统而言，前处理不仅需要改善主观视觉质量，还必须兼顾计算复杂度、时域一致性、显存开销与部署延迟。在带宽和存储资源受限的场景中，如何在编码前抑制对主观感受影响较小、却显著消耗码率的冗余信息，已成为前处理研究的核心问题。

2.2.1 编码器感知前处理的发展脉络

从研究脉络看，早期相关工作多源自通用图像复原与去噪任务。近年来，学术界提出了大量针对视频或图像去噪（Denoising）的前处理与后处理模型，如表 2.3 所示。这类模型大多服务于离线画质增强，其设计目标主要是在公开数据集上获得更高的 PSNR/SSIM 等客观指标。尽管这类方法在画面修复上效果显著，但其典型应用场景通常不具备严格的实时和低延迟约束，且缺乏对视频编码链路的直接建模。若将此类脱离编码器约束的大模型直接前置到编码器之前，往往难以满足直播、会议和边缘编码等在线业务对吞吐率与时延的要求。

为了克服传统画质修复模型计算开销大、与编码系统解耦的局限性，编码器感知（Encoder-aware）^①前处理逐渐成为在线传输领域的研究热点。这类方法的核心不再是孤立地提升复原指标，而是在模型设计和训练过程中显式考虑后续编码器的压缩特性。如表 2.4 所示，相关方法经历了从 Down-sampling+SR^[11] 这类间接码率约束方案，到 RR-DnCNN v2.0^[23] 的联合恢复框架，再到可利用 QP 等编码参数的 EA-MCTF^[13]、面向极低复杂度部署的 ELIM^[24] 以及引入代理网

① 编码器感知（Encoder-aware）指前/后处理算法不再盲目优化均方误差等客观指标，而是通过代理网络、提取编码参数（如 QP、运动向量）或与真实编码器交互的方式，主动适应后续视频编码引擎的压缩机制与实际码流分配策略，从而达到联合优化视觉质量和压缩效率的目的。

表 2.3 离线去噪大模型客观指标综合对比（PSNR，彩色高斯去噪 $\sigma = 15$ ）

Method	CBSD68	Kodak24	McMaster	Urban100
IRCNN	33.86	34.69	34.58	33.78
FFDNet	33.87	34.63	34.66	33.83
DnCNN ^[22]	33.90	34.60	33.45	32.98
DRUNet	34.30	35.31	35.40	34.81
SwinIR	34.42	35.34	35.61	35.13
Restormer	34.40	35.35	35.61	35.13
Xformer	34.43	35.39	35.68	35.29
MambaIR	34.48	35.42	35.70	35.37
MambaIRv2	34.48	35.43	35.73	35.42

络的 RPP^[8] 的演进过程，体现出前处理技术正不断向编码器耦合更紧、复杂度更低、部署性更强的方向发展。

本文所采用的 RAPNet 前处理框架及其衍生方案，则进一步将强化学习引入编码器感知环节。通过令前处理模型与真实的硬件编码器（如 NVENC/AVS）进行环境交互（Codec-in-the-loop），该类方法能够直接利用编码反馈进行策略寻优，同时严格控制参数量与推理开销，以满足流媒体场景对极低延迟的要求。

表 2.4 编码器感知前处理方法对比表

方法	编码器感知	Codec-in-the-loop 训练	面向编码器	核心目标	参数量/实时性	适用阶段
Down-sampling+SR ^[11]	弱 (间接约束码率)	否	泛用	降采样节约带宽	需配套超分/较慢	编码前缩放 + 解码后超分
RR-DnCNN v2.0 ^[23]	弱 (联合优化误差)	否 (端到端重训练)	HEVC 等	频域恢复与重建	多分支 CNN/中等	编码前滤波 + 解码后重建
EA-MCTF ^[13]	是 (提取 QP 等特征)	否 (传统自适应滤波)	HEVC	联合时空特征降噪	无 (分块算法)/快	编码前单独滤波
RPP ^[8]	是 (利用替代 Proxy)	否 (通过代理网络间接结合)	泛用 (HEVC 等)	滤除高频/节约码率	~ 百万级 CNN/慢	编码前单独预处理
RAPNet ^[19]	是 (提取环境特征)	是 (与真实测试集交互评估)	AVS3/VVC 等	动态策略增强画质	<1M / 极快	编码前期实时干预
本文方案	是 (NVENC 真实反馈)	是 (强化学习探索策略)	NVENC	算力自适应/低码率视觉提升	113K/<10ms	编码前端极低延迟旁路

2.2.2 面向实时编码的模型选型

从更广义的视觉主干网络演进看，AlexNet^[25] 标志着深度卷积网络在大规模视觉任务中的突破，推动了后续视觉表征学习的快速发展；ResNet^[26] 进一步通过残差连接缓解了深层网络训练退化问题，使更深的特征提取网络成为可能。随后，Transformer 凭借自注意力机制在自然语言处理中取得突破^[27]，并催生了 GPT^[28] 等生成式预训练范式，进一步证明了大规模注意力建模的通用性。该路线随后被迁移到视觉领域，ViT^[29] 首次系统验证了纯 Transformer 结构在图像识别中的可行性，Swin Transformer^[30] 通过分层结构与滑动窗口机制改善了局部建

模与复杂度控制，MAE^[31]则进一步展示了自监督掩码重建预训练在视觉表征学习中的潜力。

从视频任务的发展脉络看，Karpathy 等人^[32]较早将深度学习系统性地用于大规模视频分类任务，证明了卷积网络能够直接从视频帧中学习判别特征；随后，双流网络^[33]通过显式引入光流分支进行时序建模，在动作识别任务上首次稳定超越手工特征方法。进一步地，TimeSformer^[34]将时空注意力直接用于视频建模，通常被视为视频 Transformer 范式的重要代表工作之一。这些研究说明，视频模型的核心能力正在从局部卷积特征提取逐步走向显式时空关系建模，但与此同时，模型复杂度与部署成本也随之快速上升。

回到本文关注的实时前处理场景，骨干网络大致经历了由传统 CNN 到 Transformer，再到状态空间模型的过程。以 DnCNN^[22]为代表的早期 CNN 方法结构简单、易于部署，但感受野有限，难以充分建模长距离依赖，容易在强压缩场景下造成纹理损失和过度平滑。以 SwinIR^[35]为代表的 Transformer 方法则继承了 Swin Transformer 的分层自注意力思想^[30]，通过更强的全局建模能力在图像复原任务上取得了更优性能，但其计算复杂度随分辨率呈二次增长，对于 1080p 及以上视频难以满足实时部署要求。

在这一背景下，VRT^[5]、RVRT^[6]、改进 EDVR^[36]和 BasicVSR++^[14,37]等高性能视频复原模型更适合作为性能与复杂度对比参照，而非本文直接采用的前处理方案。如表 2.5 和表 2.6 所示，这类模型在公开数据集上具备较强恢复能力，但对应的参数量、显存占用和推理时延仍然偏高，难以直接嵌入实时硬件编码流水线。

为了验证不同模型在实际部署中的可行性，表 2.6 详细对比了主流模型在 320×180 输入尺寸下的参数量与推理耗时。数据显示，VRT 的显存占用高达 2149M，而 BasicVSR++ 在保持较高 PSNR (32.39dB) 的同时，显存仍需 223M、推理时延仍为 77ms，说明即便是相对高效的视频复原模型，也与实时前处理的部署约束存在明显差距。

进一步看轻量化方向，以 MambaIR^[38]为代表的状态空间模型将计算复杂度降低至线性级别，同时保留了较强的长距离依赖建模能力。表 2.7 给出了若干轻量级模型在超分任务上的对比结果，可以看到 MambaIR 系列在相近参数规模下表现出较稳妥的重建性能与复杂度平衡。虽然这些结果来自复原任务，但其轻量

表 2.5 视频超分辨率模型性能对比（PSNR(dB)/SSIM），数据整理自文献^[6]

Method	BI-REDS4 (RGB)	BI-Vimeo (Y)	BI-Vid4 (Y)	BD-UDM10 (Y)	BD-Vimeo (Y)	BD-Vid4 (Y)
Bicubic	26.14/0.7292	31.32/0.8684	23.78/0.6347	28.47/0.8253	31.30/0.8687	21.80/0.5246
SwinIR	29.05/0.8269	35.67/0.9287	25.68/0.7491	35.42/0.9380	34.12/0.9167	25.25/0.7262
DUF	28.63/0.8251	–	27.33/0.8319	38.48/0.9605	36.87/0.9447	27.38/0.8329
RBPN	30.09/0.8590	37.07/0.9435	27.12/0.8180	38.66/0.9596	37.20/0.9458	27.17/0.8205
EDVR	31.09/0.8800	37.61/0.9489	27.35/0.8264	39.89/0.9686	37.81/0.9523	27.85/0.8503
BasicVSR	31.42/0.8909	37.18/0.9450	27.24/0.8251	39.96/0.9694	37.53/0.9498	27.96/0.8553
IconVSR	31.67/0.8948	37.47/0.9476	27.39/0.8279	40.03/0.9694	37.84/0.9524	28.04/0.8570
VRT	32.19/0.9006	38.20/0.9530	27.93/0.8425	41.05/0.9737	38.72/0.9584	29.42/0.8795
BasicVSR++	32.39/0.9069	37.79/0.9500	27.79/0.8400	40.72/0.9722	38.21/0.9550	29.04/0.8753
RVRT	32.75/0.9113	38.15/0.9527	27.99/0.8462	40.90/0.9729	38.59/0.9576	29.54/0.8810

表 2.6 主流模型参数与效率对比（320 × 180 输入），数据整理自文献^[6]

Method	#Param (M)	Memory (M)	Runtime (ms)	PSNR (dB)
BasicVSR++	7.3	223	77	32.39
BasicVSR++ + RSTB	9.3	1021	201	32.61
EDVR	20.6	3535	378	31.09
VSRT	32.6	27487	328	31.19
VRT	35.6	2149	243	32.19
RVRT	10.8	1056	183	32.75

化、强表征和低时延特征，与实时编码前处理的需求更为一致。

为了更直观地展示不同技术路线的特性，表 2.8对比了各主流模型在复杂度与性能上的差异。

综合上述分析可以看出，AI辅助视频编码的发展趋势正从单纯追求 PSNR/SSIM 等客观指标，转向与硬件编码器紧密结合、性能与效率协同优化的方向^[4]。从表 2.8可以看到，VRT、RVRT 和 BasicVSR++ 等模型虽然在复原任务中具有代表性，但其实时性仍不足以支撑 NVENC 流水线中的在线前处理。相比之下，参数规模更小、复杂度更低的轻量化模型更符合本文场景需求。因此，本文优先考虑参数量低于 1M、推理时延低于 10ms 的前处理路线，并以此作为后续 RAPNet 方案设计与优化的选型依据。

表 2.7 主流轻量级模型参数与效率对比，数据整理自文献^[38]

Method	Scale	#Param	MACs	Set5	Set14	Manga109
				PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
CARN	2x	1,592K	222.8G	37.76/0.9590	33.52/0.9166	38.36/0.9765
SwinIR-light	2x	910K	244.2G	38.14/0.9611	33.86/0.9206	39.12/0.9783
MambaIR-light	2x	905K	334.2G	38.13/0.9610	33.95/0.9208	39.20/0.9782
ELAN	2x	621K	203.1G	38.17/0.9611	33.94/0.9207	39.11/0.9782
SRFormer-light	2x	853K	236.3G	38.23/0.9613	33.94/0.9209	39.28/0.9785
MambaIRv2-light	2x	774K	286.3G	38.26/0.9615	34.09/0.9221	39.35/0.9785
SwinIR-light	3x	918K	111.2G	34.62/0.9289	30.54/0.8463	33.98/0.9478
MambaIR-light	3x	913K	148.5G	34.63/0.9288	30.54/0.8459	34.12/0.9479
MambaIRv2-light	3x	781K	126.7G	34.71/0.9298	30.68/0.8483	34.41/0.9497
SwinIR-light	4x	930K	63.6G	32.44/0.8976	28.77/0.7858	30.92/0.9151
MambaIR-light	4x	924K	84.6G	32.42/0.8977	28.74/0.7847	30.94/0.9135
MambaIRv2-light	4x	790K	75.6G	32.51/0.8992	28.84/0.7878	31.24/0.9182

表 2.8 主流模型复杂度与性能综合对比

模型架构	适用阶段	参数量	推理耗时	显存占用	性能评价	备注
VRT	仅限离线后处理	~30–35M	>200ms	2149M	当前最优	综合性能最优
RVRT	后处理/前处理	~10.8M	183ms	1056M	接近 VRT	效率与性能较均衡
BasicVSR++	前处理推荐	~7.3M	77ms	223M	较优	参数效率突出
MambaIR	前处理推荐	<1M	<10ms	<100M	优于传统 CNN	线性复杂度

2.3 后处理技术分析

后处理通常在解码后进行，主要用于修复压缩失真、抑制块效应与振铃效应，或进一步执行超分辨率重建^[14]。VRT^[5]、RVRT^[6]和 BasicVSR++^[14,37]是该方向具有代表性的工作。本文保留这些模型的引用与复杂度对比，主要是将其作为性能参照和技术背景说明，用以反衬实时场景下轻量化前处理方案的必要性。

尽管后处理技术在低码率场景下能够改善解码后视觉效果，但它通常发生在编码完成之后，难以直接降低编码阶段的码率开销，也会进一步增加端到端链路时延。因此，相较于后处理，本文更关注能够在编码前直接影响码率分配与压缩行为的前处理技术，并将其作为后续研究的核心对象。

2.4 强化学习基础

强化学习（Reinforcement Learning, RL）通过智能体与环境的持续交互学习决策策略，其核心目标是最大化长期累计回报。在本文场景中，前处理网络无法直接对硬件编码器内部过程求导，因此更适合采用与编码环境交互并根据反馈更新策略的强化学习范式。形式上，该问题可建模为马尔可夫决策过程 (S, A, P, R, γ) ：状态 s_t 描述当前可观测视频片段及上下文，动作 a_t 对应前处理后的输出帧，奖励 r_t 则反映该动作在码率与感知质量上的综合收益。长期优化目标通常写为

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}, \quad (2.1)$$

其中 $\gamma \in [0, 1]$ 表示折扣因子，用于平衡短期收益与长期收益。

在学习机制上，经典时序差分方法通过估计与自举相结合的方式更新价值函数。Sarsa 采用行为策略下的下一动作进行更新，其形式为

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)], \quad (2.2)$$

而 Q-Learning 采用下一状态的最大价值进行更新，形式为

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right], \quad (2.3)$$

二者在低维离散控制问题中有效，但在视频前处理这类高维连续动作空间中，直接构建离散动作价值表会带来严重的维度与样本效率瓶颈。

为此，本文采用策略梯度与价值评估结合的 Actor-Critic 框架。策略目标可写为

$$J(\theta) = \mathbb{E}_{s_0} [V^{\pi_\theta}(s_0)], \quad (2.4)$$

其梯度形式为

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [Q^{\pi_\theta}(s, a) \cdot \nabla_\theta \log \pi_\theta(a|s)], \quad (2.5)$$

对应到确定性策略实现，可用

$$\nabla_\theta J \approx \nabla_\theta Q_\phi(s, \pi_\theta(s)) \quad (2.6)$$

近似 Actor 更新方向；Critic 则通过最小化

$$\mathcal{L}_{\text{Critic}} = \text{MSE}(Q_\phi(s, a), r) \quad (2.7)$$

学习价值评估。在视频编码领域，文献^[16]已证明强化学习能有效应用于 HEVC 帧级码率分配；AVS M9322 提案^[19]进一步将其扩展到基于 RAPNet 的前处理滤波工具中，说明其在提升编码器率失真性能方面具有进一步研究价值。

2.5 本章小结

本章首先回顾了视频编码标准的演进历程,重点分析了 H.265/HEVC 标准^[1]、NVENC 硬件编码器及与后续实验相关的基本编码框架,并介绍了基于 FFmpeg 的硬件编解码工具链。随后重点梳理了前处理技术从通用图像复原到编码器感知协同优化的发展脉络,并结合 CNN^[23]、Transformer^[5,35] 和状态空间模型^[38] 等不同架构的复杂度与性能特征,明确了面向实时编码场景的轻量化选型依据。最后系统介绍了强化学习的基础理论,为后续章节的系统设计奠定了理论基础。

3 系统设计与实现

本章详细阐述基于 Actor-Critic 架构的视频前处理优化系统的整体设计与实现。在进入具体设计之前，有必要说明本方案的选型过程。在项目早期，首先尝试了基于监督学习的率感知预处理方案 RPP^[8]。RPP 通过自适应 DCT 损失函数智能去除高频冗余，在原生分辨率、软件编码器 (x265) 的测试中取得了显著的 BD-Rate 收益。然而，将其部署到 NVENC 硬件编码器的 2× 下采样流水线中时，效果却不如纯硬件基线方案。经过深入的频谱分析和反复调试，定位到两个关键问题：其一，RPP 的 DCT 优化策略是基于输入分辨率设计的，在 4K 尺度下被判定为可以牺牲的中频纹理，恰恰是下采样后 1080p 画面中仅存的清晰度来源，导致处理后画面严重发糊；其二，RPP 输出的低方差平滑信号干扰了 NVENC 码率控制算法的正常决策——硬件编码器将其识别为平坦区域并激进地提高 QP，最终造成块效应和色带，画质严重过平滑并伴随明显块状伪影。这一失败经验说明，基于监督学习的前处理方案本质上无法感知编码器的行为，必须引入一种能够将编码器纳入优化回路的训练范式。因此本文最终选择强化学习框架：将不可导的 NVENC 视为黑盒环境，通过编码器感知的方式使前处理模型能够针对硬件编码器的特性（如量化步长、块划分模式）^[9]进行预补偿，有效缓解低码率场景下的质量崩塌。

为保持章节层次清晰，本章按照系统架构与设计思路、前处理优化的设计与训练算法、模块实现与技术细节三部分展开，依次说明整体框架、优化机制以及具体实现。

3.1 系统架构与设计思路

从物理处理链路看，系统以 1080p 原始 YUV 序列为输入，先由 RAPNet 执行编码前增强，再在固定 QP 控制下进入 NVENC 硬件编解码链路，最后以感知质量与码率指标对前处理收益进行对比评估。该过程如图 3.1 所示。图中同时给出了 Baseline 分支与前处理分支在同一编码环境下的输出结果，便于直接观察 ΔV 与 ΔR 的来源及其工程意义。

图 3.1 可从三个层面理解整个系统。首先，上层主链路描述了数据流向：1080p 原始 YUV 序列进入 RAPNet 后生成前处理结果 $\hat{x}_t$ ，该结果与原始输入共同送入后续编码环境。其次，中间部分给出了统一的控制条件，即系统在固定 CQP 模




图 3.1 总体前处理流程图

式和多 QP 配置下调用 NVENC/NVDEC 或 FFmpeg 解码链路，从而保证 Baseline 分支与前处理分支处于完全一致的编码约束下。最后，下层评价模块分别输出两条分支的 Bitrate 和 VMAF/LPIPS，并通过 ΔV 与 ΔR 完成率失真增益分析。

这种双分支并行设计的关键作用在于隔离变量，使前处理模块成为系统中唯一的主动干预因素。换言之，图中的 ΔV 和 ΔR 并不反映通用增强模型的离线复原能力，而是专门刻画 RAPNet 对 NVENC 编码行为的影响。当 RAPNet 抑制了编码器不敏感的高频冗余、或增强了更利于压缩保持的结构信息时，这些变化会进一步传导到块划分、量化和码率分配过程中，最终体现为感知质量与码率开销的联动变化。

3.1.1 Actor-Critic 反馈闭环

在本文系统中，Agent 由 Actor 与 Critic 共同构成，而非单一网络。Actor 对应 RAPNet，负责在状态 s_t 下生成前处理动作 a_t ；Critic 对应 ValueNet，负责评估状态—动作对的价值并提供策略优化方向。其基本决策关系如式 (3.1) 和式 (3.2) 所示，其中式 (3.1) 给出策略生成机制，式 (3.2) 给出价值评估机制，二者构成策略学习的核心耦合关系：

$$a_t = \pi_{\theta}(s_t), \quad (3.1)$$

$$q_t = Q_\phi(s_t, a_t), \quad (3.2)$$

其中 θ 与 ϕ 分别表示 Actor 和 Critic 参数。

Environment 由真实硬件编解码流程与质量评估模块共同定义，对应代码中的 NvencClipEnvQP。在给定 QP 条件 q 下，环境对动作执行编码、解码与评估并返回奖励，可抽象为

$$(s_{t+1}, r_t^{(q)}) = \mathcal{E}(s_t, a_t, q), \quad q \in \mathcal{Q}, \quad (3.3)$$

其中 $\mathcal{Q} = \{37, 40, 42, 45, 47\}$ 。单 QP 奖励采用质量增益与码率节省的线性加权形式

$$r_t^{(q)} = \alpha \cdot \Delta V_t^{(q)} + \beta \cdot \Delta R_t^{(q)}, \quad (3.4)$$

式中 $\Delta V_t^{(q)}$ 由感知质量指标计算（可配置为 VMAF 或 LPIPS 映射分数）， $\Delta R_t^{(q)}$ 由 Bitrate 相对变化计算。跨 QP 训练时，采用平均回报作为最终反馈信号

$$\bar{r}_t = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} r_t^{(q)}. \quad (3.5)$$

上述映射下的完整交互关系见图 3.2。该闭环明确了状态输入、动作生成、环境执行、奖励构建与损失回传之间的先后依赖，是后续状态空间、动作空间与奖励函数建模的统一语义基础。

图 3.2 进一步说明了 Actor-Critic 框架在本文任务中的具体分工。从整体上看，图中左侧的 State、上方的 Actor 以及下方的 Critic 共同构成 Agent，它们负责根据当前输入状态生成前处理策略并持续完成自我更新。具体而言，State 模块对应当前输入的 Y/Cb/Cr 视频片段；Actor 根据状态生成动作 a_t ，即前处理后的候选视频帧；Environment 则负责执行真实的编码、解码和质量评估过程，并根据相对 Baseline 的质量变化和码率变化生成奖励。与传统监督学习直接最小化重建误差不同，这里的奖励来自真实硬件编码反馈，因此能够直接反映动作是否有利于低码率场景下的率失真优化。

图中下方的 Critic 承担价值评估角色。它同时感知状态与动作，并根据 Environment 返回的奖励学习 $Q_\phi(s_t, a_t)$ ，从而判断当前动作在长期收益意义下是否值得保留。Critic 的输出通过价值引导作用于 Actor，帮助 Actor 逐步学会在增强结构信息与抑制冗余纹理之间找到更合适的平衡点。上方的 Hybrid Loss 则进一步对 Actor 施加频域和空间平滑约束，使策略优化不至于走向过锐化或高频噪声




图 3.2 整体强化学习框架示意图

堆积。整体而言，图 3.2 给出的不是简单的前向推理过程，而是一个围绕真实编码器反馈不断闭环修正的策略学习系统。

3.2 前处理优化的设计与训练算法

3.2.1 状态、动作与训练样本构建

定义 t 时刻的状态空间 s_t 为待编码的原始视频帧序列。鉴于 NVENC 硬件编码器及主流视频标准广泛采用 YCbCr 4:2:0 格式，系统首先通过双线性插值 (Bilinear Interpolation) 将下采样的色度分量 (Cb, Cr) 上采样至与亮度分量 (Y) 相同的空间分辨率。最终构建的输入状态张量形状为 $(B \times T, 3, H, W)$ ，其中 T 为时序长度，旨在利用视频帧间的时域相关性辅助决策。

为了克服直接生成像素可能导致的训练震荡与收敛困难问题，系统采用残差学习 (Residual Learning) 策略^[26]。Agent 的输出并非直接的像素值，而是针对原始帧的残差修正量。定义 t 时刻的状态为原始视频帧 s_t ，网络输出为残差图 $f_{\text{Actor}}(s_t)$ ，则最终生成的动作 a_t 表示为：

$$a_t = \text{clamp}(s_t + f_{\text{Actor}}(s_t), 0, 1) \quad (3.6)$$

其中， $\text{clamp}(\cdot, 0, 1)$ 操作用于将叠加后的像素值强制约束在合法区间 $[0, 1]$

内，确保输入硬件编码器的视频帧数据有效。

在早期的系统设计中，训练时采用 $2\times$ 下采样将 1080p 视频缩小为 540p 进行编码。在该方案下，模型的 PSNR 指标有所提升，但主观观看时却发现画面边缘明显模糊、纹理细节丢失严重。对训练数据进行频谱分析表明问题主要来自：下采样操作直接截断了 Nyquist 频率以上的高频分量，导致模型从一开始就没有真实的高频纹理，自然也无法学会保护这些细节。这一失败经验表明，训练数据的构建方式需要重新审视。

为此，本文提出了基于随机裁剪 (Random Crop) 的训练策略：从 1080p 原始帧中随机裁剪 960×540 的区域作为训练样本。该策略在保持与下采样方案相同的编码分辨率和计算开销的前提下，完整保留了原始视频的高频信息。核心实现如代码 3.1 所示。

```

1  def random_crop_yuv420_clip(y, cb, cr, crop_h, crop_w):
2      # Random crop a fixed-size region from YUV420 clip
3      # y: (T,1,H,W)      Luma channel
4      # cb: (T,1,H/2,W/2) Chroma Cb channel
5      # cr: (T,1,H/2,W/2) Chroma Cr channel
6      # crop_h, crop_w:   Crop size (must be even)
7      T, _, H, W = y.shape
8      # Random start position (aligned to 2 for YUV420)
9      top = random.randint(0, H - crop_h) // 2 * 2
10     left = random.randint(0, W - crop_w) // 2 * 2
11     # Crop Y channel
12     y_crop = y[:, :, top:top+crop_h, left:left+crop_w]
13     # Crop Cb/Cr channels (half resolution)
14     top_c, left_c = top // 2, left // 2
15     crop_h_c, crop_w_c = crop_h // 2, crop_w // 2
16     cb_crop = cb[:, :, top_c:top_c+crop_h_c,
17                    left_c:left_c+crop_w_c]
18     cr_crop = cr[:, :, top_c:top_c+crop_h_c,
19                    left_c:left_c+crop_w_c]
20     return y_crop, cb_crop, cr_crop
    
```

Listing 3.1: YUV420 Random Crop

需要特别注意的是, YUV 4:2:0 格式要求裁剪坐标必须是 2 的倍数, 以保证亮度与色度通道的空间对齐。在环境的 `reset()` 方法中, 每个 episode 都会随机选择新的裁剪位置, 从而实现数据增强效果。

3.2.2 奖励机制与损失函数

针对低码率场景下主观画质与传输带宽的平衡问题, 设计了基于参考率失真 (Reference Rate-Distortion) 特性的复合奖励函数。该函数旨在引导模型在相对于基准编码器 (Baseline) 的相对增益中寻找平衡点, 其数学形式定义如下:

$$R_{total} = \alpha \cdot \frac{V_{cur} - V_{ref}}{|V_{ref}|} + \beta \cdot \frac{R_{ref} - R_{cur}}{R_{ref}} \quad (3.7)$$

式中, V_{cur} 和 R_{cur} 分别为当前动作经 NVENC 编码后解码获得的感知质量分数 (采用 LPIPS 取负, 值越大表示质量越好) 和实际码率 (kbps); V_{ref} 和 R_{ref} 为基准编码器在同等量化参数 (QP) 下的参考值。 $\alpha = 200$ 与 $\beta = 100$ 为超参数, 分别用于调控感知质量增益与码率节省的权重。

为了实现跨 QP 点的泛化能力, 系统在每个训练 step 中对同一段视频分别在 $QP \in \{37, 40, 42, 45, 47\}$ 五个量化参数下进行编码, 取所有 QP 点的平均奖励作为最终奖励信号:

$$\bar{r}_t = \frac{1}{|Q|} \sum_{q \in Q} R_{total}(q) \quad (3.8)$$

为了确保 Actor-Critic 架构的稳定收敛, 针对 Critic 和 Actor 网络分别设计了差异化的优化目标。

Critic 网络 (ValueNet) 旨在准确评估当前策略的价值, 其训练目标是最小化预测 Q 值与真实奖励 R_{total} 之间的均方误差 (MSE):

$$\mathcal{L}_{Critic} = \text{MSE}(V(s_t, a_t), R_{total}) \quad (3.9)$$

Actor 网络 (RAPNet) 的损失函数采用频域感知的复合损失策略, 由策略梯度损失和多个空间频率感知正则项构成:

$$\mathcal{L}_{Actor} = \underbrace{-Q_\phi(s, \pi_\theta(s))}_{\text{策略梯度}} + w_{mse} \cdot \mathcal{L}_{mse} + w_{hf} \cdot \mathcal{L}_{hf} + w_{TV} \cdot \mathcal{L}_{TV} \quad (3.10)$$

各项的具体定义如下:

(1) **策略梯度损失** $\mathcal{L}_{\text{policy}}$: 旨在最大化 Critic 对当前动作的评分, 引导网络生成高回报的增强帧。通过最大化该估值（即在损失函数中取负号进行最小化）, 迫使 Actor 网络朝着 Critic 认为能够获得更高奖励的方向调整输出动作:

$$\mathcal{L}_{\text{policy}} = -\mathbb{E}[Q_{\phi}(s_t, f_{\text{Actor}}(s_t))] \quad (3.11)$$

(2) **加权 MSE 损失** $\mathcal{L}_{\text{mse}}$: 用于约束生成帧与原始帧在低频内容上的结构一致性, 防止色彩偏移。采用加权均方误差形式（亮度通道权重更高）:

$$\mathcal{L}_{\text{mse}} = 6 \cdot \text{MSE}(Y, \hat{Y}) + 1 \cdot \text{MSE}(C_b, \hat{C}_b) + 1 \cdot \text{MSE}(C_r, \hat{C}_r) \quad (3.12)$$

(3) **非边缘高频抑制损失** $\mathcal{L}_{\text{hf}}$: 这是本文损失设计的关键组成部分。利用 Sobel 算子对原始帧进行边缘检测, 生成软边缘掩模 $E \in [0, 1]$ （边缘处值高、平坦处值低）, 然后仅在**非边缘区域**惩罚 Actor 引入的高频修改:

$$\mathcal{L}_{\text{hf}} = \frac{1}{N} \sum |\text{HP}(\delta)| \cdot (1 - E) \quad (3.13)$$

其中, $\delta = a_t - s_t$ 为 Actor 输出的修改量, $\text{HP}(\cdot) = \delta - \text{LP}(\delta)$ 为高通滤波（减去 5×5 均值模糊的低频分量）, E 为 Sobel 边缘掩模（通过 $E = 1 - e^{-k \cdot \hat{e}}$ 生成软掩模, $k = 10$ 控制掩模锐度）。该设计允许模型在边缘区域自由修改以增强锐度, 但在平坦区域抑制高频噪声以避免编码器浪费码率。

(4) **全变分平滑损失** $\mathcal{L}_{\text{TV}}$: 为了抑制由卷积操作引起的棋盘格伪影及高频噪声, 引入各向异性全变分损失 (Anisotropic Total Variation Loss)。该损失通过最小化相邻像素间的差异来提升图像的空间平滑度:

$$\mathcal{L}_{\text{TV}} = \frac{1}{N} \sum_{b,c,h,w} [(\hat{x}_{b,c,h+1,w} - \hat{x}_{b,c,h,w})^2 + (\hat{x}_{b,c,h,w+1} - \hat{x}_{b,c,h,w})^2] \quad (3.14)$$

其中, $N = B \times C \times H \times W$ 为归一化因子, 确保损失数值不随分辨率变化而波动; $\hat{x}$ 代表 Actor 输出的增强帧。训练中各损失权重设置为 $w_{\text{mse}} = 5$ 、 $w_{\text{hf}} = 10$ 、 $w_{\text{TV}} = 0.1$ 。

3.3 模块实现与技术细节

3.3.1 Actor-Critic 网络实现

RAPNet (Rate-Adaptive Pre-processing Network)^[19] 采用具备线性复杂度的轻量级架构, 参数量为 113K。相较于计算开销较大的 Transformer 架构^[5], 本文




图 3.3 基于 Actor-Critic 架构的视频前处理优化系统框图

采用具备线性复杂度的轻量级网络作为核心骨干^[8]。完整的网络架构如图 3.3 所示。

图 3.3 从网络实现层面给出了系统内部模块的组织方式。图中的 Actor 对应 RAPNet，负责对输入帧进行轻量化残差增强；Critic 对应 ValueNet，用于评估当前前处理动作对率失真收益的贡献。两者并不是彼此独立的两个网络，而是围绕同一状态和动作协同工作：Actor 负责生成可执行方案，Critic 负责评估方案优劣，从而使强化学习框架真正落到具体的视频前处理模型上。

Actor 网络（RAPNet）采用 PixelUnshuffle、残差学习和 PixelShuffle 构成的编码-解码结构：

(1) **输入层**: 先将亮度 Y 与上采样到亮度分辨率的色度 Cb/Cr 拼接为 $(3, H, W)$ 输入, 再通过 PixelUnshuffle 重排为 $(12, H/2, W/2)$, 随后使用 3×3 卷积 + LeakyReLU 提取浅层特征;

(2) **主干层**: 5 个 ResBlock 进行残差学习, 每个 ResBlock 包含 3×3 卷积 + LeakyReLU + 3×3 卷积 + 残差连接;

(3) **输出层**: 主干特征经 3×3 卷积映射回 12 通道后, 通过 PixelShuffle 恢复为 $(3, H, W)$ 残差, 再与输入做残差叠加; 其中 Cb/Cr 分量在输出前再下采样回 YUV420 对应的色度分辨率。

从算子定义看, PixelUnshuffle(2) 对单通道输入可实现 $(1, H, W) \rightarrow (4, H/2, W/2)$ 的空间重排; 然而在本文 RAPNet 实现中, 该算子实际作用于亮度 Y 与经上采样后的色度 Cb/Cr 拼接形成的三通道张量, 因此其网络级输入输出关系应表述为 $(3, H, W) \rightarrow (12, H/2, W/2)$ 。这种先通道拼接、后空间重排的设计, 使模型能够在低分辨率特征域内联合建模亮度与色度之间的相关性, 并在控制参数量与计算复杂度的同时完成跨通道残差增强。

Critic 网络 (ValueNet) 采用双分支特征融合架构:

- (1) 输入分支与输出分支分别通过 Conv + LeakyReLU + Conv 提取特征;
- (2) 特征融合: Concat 两个分支特征;
- (3) 回归预测: 3×3 卷积 $\rightarrow$ 全局平均池化 (AvgPool) $\rightarrow$ MLP (Linear $\rightarrow$ ReLU $\rightarrow$ Linear) 输出标量 Q 值。

该双分支架构使 Critic 能够同时感知原始输入和 Actor 输出的差异, 从而更准确地评估动作价值。

3.3.2 编码环境与训练流程

系统基于 NVIDIA Video Codec SDK 搭建真实编码环境, 通过 FFmpeg 调用 NVENC 硬件编码器实现视频帧在训练循环中的实时编解码。编码 $\rightarrow$ 解码 $\rightarrow$ 质量评估的完整流程通过 FFmpeg 命令行调用实现, 其核心代码如代码 3.2 所示。

```

1 # === Encode: YUV frames -> HEVC bitstream ===
2 encode_cmd = [
3     ffmpeg_bin, "-y",
4     "-f", "rawvideo", "-pix_fmt", "yuv420p",
5     "-s:v", f"{W_enc}x{H_enc}",      # Resolution 960x540
6     "-r", str(fps),                  # Frame rate
    ]
    
```

```

7     "-i", yuv_input_path,          # Input: preprocessed YUV
8     "-c:v", "hevc_nvenc",         # NVENC hardware encoder
9     "-rc", "constqp",             # Constant QP mode
10    "-qp", str(qp),                # Quantization parameter
11    "-preset", "p4",               # Preset (p4=medium)
12    "-profile:v", "main",          # Main Profile
13    "-pix_fmt", "yuv420p",
14    bitstream_path,                # Output: HEVC bitstream
15 ]
16 subprocess.run(encode_cmd, check=True,
17                 stdout=subprocess.DEVNULL, stderr=log_file)
18 # === Decode: HEVC bitstream -> YUV frames ===
19 decode_cmd = [
20     ffmpeg_bin, "-y",
21     "-i", bitstream_path,          # Input: HEVC bitstream
22     "-f", "rawvideo",
23     "-pix_fmt", "yuv420p",
24     decoded_yuv_path,              # Output: decoded YUV
25 ]
26 subprocess.run(decode_cmd, check=True,
27                 stdout=subprocess.DEVNULL,
28                 stderr=subprocess.DEVNULL)
29 # === Quality: compute LPIPS and bitrate ===
30 V_cur = compute_lpips(ref_clip_bgr, decoded_clip_bgr)
31 bitrate_kbps = video_size_kb * 8192 / 1000.0 / duration
    
```

Listing 3.2: NVENC Encode-Decode-Evaluate Pipeline

编码环境的核心参数配置如表 3.1 所示。

本文的训练算法基于 Actor-Critic 框架,采用多 GPU 并行策略:Actor(RAPNet)部署在 GPU 0 上, Critic(ValueNet) 部署在 GPU 1 上,通过参数同步机制保持一致性。训练过程中的完整执行链路如图 3.4 所示。

在代码执行层面,训练 Pipeline 可归纳为采样状态、生成动作、硬件评估和网络更新构成的单步迭代闭环。环境先从数据集中随机采样并裁剪 YUV 片段构造状态,Actor 输出前处理动作后,环境在多 QP 设置下调用 FFmpeg 与 NVENC

表 3.1 NVENC 编码环境参数配置

参数	设置
编码标准	H.265/HEVC
编码器	hevc_nvenc
码率控制	constqp（恒定 QP 模式）
QP 范围	{37, 40, 42, 45, 47}
编码预设	p4（medium，编码质量与速度的平衡点）
编码档次	Main
像素格式	YUV420p
编码分辨率	960 × 540

完成编码与解码，并提取 VMAF/LPIPS 与 Bitrate 指标，计算相对 Baseline 的奖励，再由 Critic 与 Actor 分别完成价值拟合与策略更新。




图 3.4 代码训练流程总览

图 3.4展示了训练过程在实现层面的逐步展开方式。首先，环境随机选择视频片段、起始帧并读取连续 16 帧 YUV 数据；随后执行 Random Crop，构造满足当前编码分辨率约束的状态 s_t 。其次，Actor 根据状态输出前处理动作 a_t ，并将结果写入临时 YUV 文件，供后续硬件编码环境调用。接着，系统针对多个 QP 点逐一执行 FFmpeg 与 hevc_nvenc 编码和解码，得到重建序列后计算当前分支

的质量指标与实际码率。然后,系统查询 Baseline RD 表,计算每个 QP 下的 ΔV 和 ΔR 并形成单 QP 奖励,最后再对所有 QP 点聚合得到平均奖励。

在参数更新阶段, Critic 首先根据平均奖励拟合当前状态—动作对的价值,随后 Actor 在 Critic 价值引导和复合正则损失约束下更新参数。图中的虚线回边表示一次迭代完成后,系统重新采样下一段视频并进入新的训练轮次。该流程强调的不是单纯的网路前向,而是真实编码反馈参与参数更新的训练闭环,这也是本文区别于传统离线画质增强方法的关键所在。

- **多 GPU 协同:** Actor 和 Critic 分别部署在不同 GPU 上, Critic 更新完毕后将参数同步到 GPU 0 上的副本 $Q_{\phi'}$ (仅用于前向推理,不参与反向传播),避免跨 GPU 的自动求导断链问题;
- **多 QP 联合训练:** 每个 step 对 5 个 QP 点编码并取平均奖励,使网络适应不同码率场景而非过拟合到单一 QP;
- **梯度裁剪:** Actor 梯度范数裁剪至 1.0, Critic 梯度范数裁剪至 10.0,防止训练早期因奖励不稳定导致梯度爆炸。

优化器采用 Adam^[39], Actor 学习率 1×10^{-5} , Critic 学习率 2×10^{-5} , 每 1000 次迭代衰减为原来的 1/3。完整的训练流程如算法 1 所示。

3.4 本章小结

本章按照系统架构与设计思路、前处理优化的设计与训练算法、模块实现与技术细节的逻辑,系统阐述了基于 Actor-Critic 架构的视频前处理优化方案。首先,通过总体前处理流程图和强化学习闭环图说明了 RAPNet、NVENC 编码环境以及奖励反馈之间的协同关系。随后,围绕前处理优化任务给出了状态与动作建模、Random Crop 训练样本构建、复合奖励函数及频域感知损失设计。最后,从网络实现和工程实现两个层面介绍了 RAPNet/ValueNet 结构、FFmpeg+NVENC 编码环境以及完整的多 GPU 训练流程,为第四章实验验证提供了实现基础。

算法 1: 基于 Actor-Critic 的编码器感知前处理训练算法

Input: 视频数据集 $\mathcal{D}$, Baseline RD 表, QP 集合 $\mathcal{Q} = \{37, 40, 42, 45, 47\}$

Output: 训练好的 Actor 网络参数 θ^*

```

1  初始化 Actor  $\pi_\theta$  (GPU 0), Critic  $Q_\phi$  (GPU 1), Critic 副本  $Q_{\phi'}$  (GPU 0);
2  构建 Baseline RD 参考表:  $\{R_{ref}(v, q), V_{ref}(v, q)\}_{v \in \mathcal{D}, q \in \mathcal{Q}}$ ;
3  for  $iter = 1$  to  $N_{max}$  do
    /* 环境重置 */
4    从  $\mathcal{D}$  随机选取视频  $v$ , 随机读取 16 帧 1080p YUV;
5    随机裁剪至  $960 \times 540$  得到状态  $s = (Y, Cb, Cr)$ ;
    /* Actor 前向: 生成动作 */
6     $a = (Y_a, Cb_a, Cr_a) \leftarrow \pi_\theta(s)$ ; // 在 GPU 0 上
    /* 环境交互: 编码-解码-评估 */
7    for  $q \in \mathcal{Q}$  do
8        将  $a$  写入 YUV 文件, 通过 hevc_nvenc 以 QP= $q$  编码;
9        解码重建帧, 计算  $V_{cur}(q)$  (LPIPS) 和  $R_{cur}(q)$  (码率);
10        $r(q) \leftarrow \alpha \cdot \Delta V(q) + \beta \cdot \Delta R(q)$ ;
11    end
12    计算平均奖励:  $\bar{r}_t \leftarrow \text{mean}(\{r(q)\}_{q \in \mathcal{Q}})$ ;
    /* Critic 更新 (在 GPU 1 上) */
13     $\mathcal{L}_{Critic} \leftarrow \text{MSE}(Q_\phi(s, a), \bar{r}_t)$ ;
14    反向传播更新  $\phi$ , 同步参数到  $Q_{\phi'}$ ;
    /* Actor 更新 (在 GPU 0 上) */
15     $\mathcal{L}_{Actor} \leftarrow -Q_{\phi'}(s, \pi_\theta(s)) + w_{mse} \cdot \mathcal{L}_{mse} + w_{hf} \cdot \mathcal{L}_{hf} + w_{TV} \cdot \mathcal{L}_{TV}$ ;
16    反向传播更新  $\theta$ , 梯度范数裁剪至 1.0;
17 end
    
```

4 实验与结果分析

4.1 实验环境与评价体系

本章围绕真实硬件编码器上的感知率失真收益能否以可接受代价实现这一问题展开验证。实验设置既覆盖训练平台与测试数据，也覆盖率失真、感知质量和部署开销三类指标，以保证后续结论同时具备算法意义和工程意义。

实验平台与数据。表 4.1和表 4.2分别给出了硬件与软件环境。训练采用双卡并行方案，Actor 与 Critic 分置于两张 RTX 4090 上，以支撑真实编码环境中的强化学习迭代。测试数据如表 4.3所示，选取 UVG 数据集^[20]中 5 个 1080p 序列，覆盖运动、自然纹理、人物与城市场景，用于检验方法在不同内容分布下的稳定性。

表 4.1 实验硬件环境配置

配置项	参数
CPU	Intel Core i9-13900K
GPU	NVIDIA RTX 4090 (48GB)× 2
内存	512 GB DDR5
操作系统	Ubuntu 22.04 LTS

注：实验中使用双卡并行进行强化学习训练（基于 *ElegantRL*^[40]），Actor 部署于 GPU 0，Critic 部署于 GPU 1，在当前硬件配置下，单次完整训练约需 1 天。

表 4.2 实验软件环境配置

软件/库	版本
Python	3.10
PyTorch	2.1.0
CUDA	12.1
FFmpeg	6.0
NVIDIA Video Codec SDK	12.0
<i>ElegantRL</i> ^[40]	与训练代码配置一致

评价体系。本文采用表 4.4中的指标对系统进行评估。其中，BD-LPIPS 是贯

表 4.3 测试视频序列

序列名称	分辨率	帧率	内容描述
BasketballDrive	1920 × 1080	50fps	运动场景（篮球）
ParkScene	1920 × 1080	24fps	自然风景（公园）
Kimono1	1920 × 1080	24fps	人物动作（和服）
Cactus	1920 × 1080	50fps	复杂纹理（仙人掌）
BQTerrace	1920 × 1080	60fps	城市场景（广场）

穿全文的核心指标,用于衡量在给定感知质量目标下的综合码率代价; ΔLPIPS 与 Δ 码率用于解释序列级变化来源;参数量、单帧推理时间和端到端时延则用于验证方案是否具备实时部署潜力。需要说明的是,LPIPS 本质上依赖预训练分类网络的深层特征空间来衡量感知距离,工程实践中常用的骨干之一为 AlexNet^[25]。本文所用 BD-LPIPS 沿用 Bjontegaard Delta 的计算框架,但将标准 BD-Rate 中以 PSNR 等客观质量指标作为质量轴的惯例改为以 LPIPS 作为质量轴;即在相同感知质量水平下比较两条 RD 曲线的平均码率差异。若记 Baseline 与 RAPNet 在公共 LPIPS 区间 $[v_{\min}, v_{\max}]$ 上的对数码率插值函数分别为 $p_{\text{base}}(v)$ 与 $p_{\text{rap}}(v)$, 则

$$\text{BD-LPIPS} = \left[\exp \left(\frac{1}{v_{\max} - v_{\min}} \int_{v_{\min}}^{v_{\max}} (p_{\text{rap}}(v) - p_{\text{base}}(v)) dv \right) - 1 \right] \times 100\%, \quad (4.1)$$

其中负值表示在相同 LPIPS 下 RAPNet 所需码率低于 Baseline, 因而代表更优的感知率失真表现。

表 4.4 实验评价指标

指标	含义	优劣方向
BD-LPIPS	以 LPIPS 为质量轴的 Bjontegaard Delta 码率差异	负值越大越好
LPIPS	基于深度学习的感知质量评价	越低越好
SSIM	结构相似性指标, 范围 $[0, 1]$	越高越好
PSNR	峰值信噪比 (dB)	越高越好
参数量	模型复杂度 (K/M 参数个数)	越少越好
推理时间	重复测量后统计的平均单帧推理耗时	越短越好

4.2 综合率失真性能与效率分析

在实验环境确定后,首先需要回答两个问题:其一,前处理是否在真实 HEVC-NVENC 链路中带来稳定的感知率失真收益;其二,这一收益是否建立在可接受的计算与时延开销之上。围绕这两个问题,本节联合分析量化结果、RD 曲线和端到端效率。

表 4.5 RAPNet 前处理框架测试结果

视频序列	Baseline 平均 LPIPS	Δ LPIPS(%)	Δ 码率 (%)	BD-LPIPS(%)
BasketballDrive	0.4664	-11.53	+1.02	-12.84
ParkScene	0.5313	-4.51	-11.08	-13.45
Kimono1	0.4513	-1.78	+3.74	-5.62
Cactus	0.4349	+1.92	-13.62	-11.15
BQTerrace	0.4250	+0.54	-4.95	-4.32
平均	0.4618	-3.07	-4.98	-9.48

表 4.5 中的各序列 BD-LPIPS 均由该序列在 $QP \in \{37, 40, 42, 45, 47\}$ 五个测试点上的 RD 曲线计算得到,表中“平均”项为 5 个序列结果的算术平均。结果显示, RAPNet 在 5 个测试序列上的 BD-LPIPS 均为负值,平均达到 -9.48%,说明本文方案在测试码率区间内能够稳定降低感知率失真代价。收益最高的 ParkScene 和 BasketballDrive 分别达到 -13.45% 和 -12.84%,表明该方法在运动明显或纹理较丰富的内容上更容易放大前处理收益; BQTerrace 的改善幅度为 -4.32%,说明高密度细纹理场景下,冗余高频与有效细节之间的边界更难区分。

从序列级结果看,策略并非单独追求更低 LPIPS 或更低码率,而是在两者之间进行自适应折中。Cactus 序列中, LPIPS 轻微上升 1.92%,但码率下降 13.62%,综合后仍取得 -11.15% 的 BD-LPIPS 收益。这说明在复杂纹理场景中,模型会主动放弃部分编码代价较高且感知收益有限的细节,以换取更优的整体率失真表现。

图 4.1 进一步验证了上述趋势。RAPNet 对应的平均 RD 曲线整体位于 Baseline 下方,意味着在相同码率下能够获得更低的 LPIPS; 等价地,在相同感知质量目标下,所需码率更低。量化表和 RD 曲线共同说明,该方法并非只在个别 QP 点或个别序列上有效,而是在整体测试区间内保持稳定收益。




图 4.1 Baseline 与 RAPNet 平均 RD 曲线对比（LPIPS vs 码率）

率失真收益只有在额外开销可控时才具备工程价值。为此，表 4.6 统计了模型参数量与单帧推理时间，表 4.7 给出了完整编码链路中的时延分解。

表 4.6 模型效率对比（输入分辨率： 960×540 ，GPU：RTX 4090；推理时间为重复测量后的平均单帧耗时）

模型	参数量	单帧推理时间 (ms)
RAPNet (本文方法)^[19]	113K	5.4
DnCNN ^[22]	668K	40
SwinIR-light ^[35]	878K	200
BasicVSR++ ^[14]	7.3M	77
RVRT ^[6]	13.6M	183
VRT ^[5]	35.6M	243

表 4.7 编码流水线各阶段时延分解（ 960×540 ，单位：ms/帧；结果为重复测量后的平均值）

QP	Read	Downsample	Pre (RAPNet)	Enc (NVENC)	Dec	E2E
37	26.7	5.9	5.4	3.3	2.7	44.1
42	26.7	5.9	5.4	3.8	2.6	44.4
45	26.7	5.9	5.4	2.9	3.2	44.1

表 4.6 显示，在相同输入分辨率和同一 RTX 4090 平台上，RAPNet 参数量仅为 113K，单帧平均推理时间为 5.4ms（同平台多次前向推理统计均值）。与 DnCNN 的 40ms、BasicVSR++ 的 77ms、RVRT 的 183ms 和 VRT 的 243ms 相比，

RAPNet 在推理时延上分别约为这些模型的 1/7.4、1/14.3、1/33.9 和 1/45.0。结合参数规模看，RAPNet 相较于 BasicVSR++ 和 VRT 的模型规模约为其 1/52 和 1/256。这说明本文方案不仅参数量更小，而且在同平台复测条件下也更接近实时编码场景的资源约束。

结合表 4.7 可见，在 QP=37/42/45 三种配置下，前处理平均耗时均为 5.4ms/帧，占端到端 44.1~44.4ms 平均时延的约 12%。相比之下，仅视频读取和下采样两项 I/O 操作就分别占用 26.7ms 和 5.9ms。本文方案以 5.4ms/帧的额外前处理代价，换取了平均 -9.48% 的 BD-LPIPS 收益，且没有成为系统主瓶颈。这一结果直接表明，轻量前处理可以嵌入真实硬件编码链路。

4.3 强化学习训练演进与案例诊断

最终结果并非来自单次稳定收敛，而是在 v1 至 v44 的迭代过程中逐步建立起来的。整个训练过程遵循先修正环境、再稳定策略、最后细化损失的演进逻辑，其中环境构建是否合理，直接决定了强化学习是否能够得到有意义的反馈。

图 4.2 展示了训练监控曲线。0~3000 次迭代内， Δ_r 波动较大但整体保持正值，说明策略优先学到的是节省码率；3000~10000 次迭代内， Δ_v 逐步接近并越过零点，说明 Actor 开始在控制码率的同时恢复感知质量；10000 次迭代后， force_q 与 force_m 的相对量级趋于稳定，训练进入以小步修正为主的收敛阶段。该过程反映的不是单一损失下降，而是奖励、约束与编码反馈之间逐步对齐的过程。

图 4.3 给出了训练过程中的典型失败案例，其中前两个案例最能说明环境设计的重要性。其一，色度通道崩塌与码率暴涨发生在 v1~v3 阶段。由于亮度损失权重大幅高于色度损失，Actor 学会了将 Cb 通道直接压零，以规避像素误差惩罚；同时，缺乏平滑约束又使输出伴随大量高频噪点，触发编码器分配更多比特。针对这一问题，本文提高了色度权重，引入 TV 约束，并使用 Tanh 限制残差幅度，从而阻止网络通过极端输出绕开约束。

其二，不公平基线导致训练停滞出现在 v3~v4 阶段。初始基线 RD 曲线基于完整视频平均码率构建，而训练环境只编码 16 帧短 clip。由于短 clip 首帧必为 I 帧，平均到每帧后的码率必然高于长序列基线，导致奖励长期为负，Agent 只能退化为恒等映射。该问题说明，对于真实编码器上的强化学习任务，环境定义本身就是优化对象的一部分。只有当训练时的基线、码率统计窗口和编码结构保






图 4.2 TensorBoard 训练监控曲线


持一致时，奖励才具有可学习性。



(a) Cb 色度通道被截断为零



(b) PixelShuffle 引发的棋盘格伪影



(c) 训练崩塌导致细节全部丢失



(d) 奖励设计不合理导致模型全面崩溃

图 4.3 训练过程中的典型失败案例

在环境问题得到修复后，训练仍经历了两类典型波动。v8~v13 阶段，Critic 曾出现梯度爆炸，随后 Actor 又因 PixelShuffle 带来棋盘格伪影；通过引入梯度裁

剪、恢复 TV 约束并将输出层初始化为零残差，训练重新回到稳定轨道。v17~v44 阶段，主要工作转向奖励设计与辅助损失的细化：过强的 MSE 约束会把 Actor 锁死在极小改动区间，而过度偏向节码的奖励又会诱导模型直接低通滤波。最终收敛到的 $w_{mse} = 5, w_{hf} = 10$ 配置，本质上是在 Critic 的策略引导力与先验损失的约束力之间找到可训练的平衡点。

4.4 增强机理与主观效果解释

在确认量化收益和训练可行性后，还需要解释模型实际改变了哪些频率成分。图 4.4 和图 4.5 给出了频域层面的观察结果，结合主观现象可以看出，RAPNet 并不是均匀增强所有高频，而是在方向性结构和非结构性纹理之间进行选择调节。




图 4.4 训练过程中图片频域变化

从图 4.5 的 Spectral Log-Diff 可以观察到，频谱中心及四条边的中点位置出现明显增强，形成十字形亮线，对应水平和垂直方向结构分量被选择性强化；四角区域变化较弱，说明模型没有在对角方向引入过多额外高频。结合 HEVC 编码器的块划分、帧内预测和方向性残差建模机制，一种可能的解释是：模型倾向于保留更利于预测和变换表示的结构信息，同时削弱对编码器不友好的杂散纹理。

上述频域观察与编码重建帧的主观结果相互印证。图 4.6 展示了典型测试帧的彩色对比，左侧为 Baseline（NVENC 直接编码重建），右侧为 RAPNet 前处理




图 4.5 模型处理前后频谱差异图（Spectral Log-Diff）




图 4.6 Baseline 与 RAPNet 彩色主观对比图（NVENC H.265 编码后重建帧，Zoom 区域为差异最显著的局部放大）

后编码重建，图中红框与黄框分别标出差异最显著的两个局部区域并放大显示。在 Zoom 1 区域可以看到，Baseline 重建中浪花与岩石交界处存在一定程度的亮度过渡不连续；RAPNet 版本中该区域过渡更平滑，纹理结构更完整。Zoom 2 所示的岩石与水体边界区域也出现类似现象：RAPNet 前处理后的重建帧在边缘细节保持上优于 Baseline，这说明前处理对 NVENC 的码率分配产生了实质性影响。

图 4.7 进一步从通道层面分析了两种方案的差异。差异图以 99 百分位绝对差值归一化，暖色（红）表示 RAPNet 重建帧亮度/色度高于 Baseline，冷色（蓝）




图 4.7 Y/Cb/Cr 各通道编码重建帧对比与差异图（差异图以 99 百分位归一化；暖色表示 RAPNet 增亮，冷色表示减暗）

表示低于 Baseline。从 Y 通道差异图可见，亮度变化在全图范围内均有分布，整体偏暖，表明 RAPNet 引导 NVENC 在亮度恢复上更为积极；船体轮廓和水面区域的局部冷色响应则对应结构边缘的针对性调整，与频谱图中水平/垂直方向的选择性增强一致。 Cb/Cr 通道的差异幅度显著小于 Y 通道（统计均值绝对差约为 Y 通道的 $1/5$ ），主要集中在水天分界线和船体轮廓附近，与第三章色度分量零均值残差约束的设计意图一致——即模型在不干扰整体色相的前提下，仅对色度边缘区域进行有限幅度的预补偿。

考虑到主观评价受显示设备和观察条件影响较大，本文仍以 BD-LPIS 和码率变化作为主要量化依据，主观观察仅用于佐证模型的增强机理。

4.5 系统消融实验与参数寻优

前述结果依赖于编码链路参数、损失函数和训练样本构造的共同配合。本节将原本分散的参数实验与消融分析合并讨论，突出两类问题：一类是训练环境如何与真实编码行为对齐，另一类是哪些约束真正决定了最终收益。

编码链路参数寻优。在正式训练前，首先需要固定 NVENC 的关键配置，以避免环境不稳定干扰策略学习。图 4.8 表明， $p1/p2/p3$ 三个预设的 RD 曲线几乎重合，而 $p4$ 在低 QP 测试区间内略优，因此本文选用 **p4 (medium)** 作为统一预

图 4.9 显示，对于 16 帧短 clip 训练场景，显式设置 $GOP=32$ 会劣于 $GOP=-1$ 默认配置，说明固定 GOP 会压缩帧间参考的灵活性。与此同时，系统全程采用 **YUV420p** 格式和 **CQP** 码率控制模式：前者保证亮度/色度对齐与 Y 域指标计算的一致性，后者消除了码率控制器的不确定性，便于在 $QP \in \{37, 40, 42, 45, 47\}$ 的测试区间内进行 BD 类指标比较。图 4.10 则说明，在需要下采样的链路中， $2\times$ 缩放能够在码率与质量之间取得较稳妥折中，而 **Lanczos** 在边缘保持方面优于更强的降采样方案，因此被作为默认下采样算法。




图 4.8 NVENC 编码预设对比实验（HEVC-NVENC, 96 帧, 1x Scale）

损失函数消融。表 4.8 给出了频域感知复合损失的平均 BD-LPIPS 结果。仅使用策略梯度损失时，平均 BD-LPIPS 为 1.21%，说明单独依赖奖励信号不足以稳定约束输出，模型容易通过局部高频扰动试探编码器反馈，反而带来码率开销。加入 MSE 像素一致性约束后，平均 BD-LPIPS 下降至 -2.37%，说明像素约束首先解决的是训练稳定性问题，使 Actor 不再轻易产生偏色或大幅残差漂移。进一步加入非边缘高频抑制项后，完整方案达到 -9.48%，较仅 MSE 约束版本额外改善 7.10 个百分点。该结果说明，真正决定最终感知率失真收益的关键并不是简单的像素保真，而是能否显式压制对编码器不友好的非结构性高频。

结合表 4.5 的分序列结果可以进一步看出，非边缘高频抑制在 **ParkScene** 和 **BasketballDrive** 上收益最为突出，分别达到 -13.45% 和 -12.84%；而 **BQTerrace** 仅为 -4.32%，说明高密度纹理场景下有效细节与可压缩冗余更难彻底分离。这也进一步证明，损失函数的核心作用不是简单增加锐度，而是通过频域先验约束策略网络的增强方向，使其选择性地作用于对编码器有利的结构信息。




图 4.9 不同 GOP 配置下的下采样算法 RD 曲线对比




图 4.10 不同下采样倍数下的 Y-PSNR 对比 (Preset: p1, GOP: Default)

表 4.8 损失函数消融实验结果（5 序列平均 BD-LPIPS, %）

配置	平均 BD-LPIPS(%)
仅策略梯度损失 $-Q$	1.21
+ MSE 像素一致性 ($w_{mse} = 5$)	-2.37
+ 非边缘高频抑制 ($w_{hf} = 10$)（完整方案）	-9.48

训练样本构造策略。表 4.9 比较了 Random Crop 与传统 2× 下采样两种训练输入构造方式。对于编码前处理任务，2× 下采样会在进入策略网络前先抹去部分高频信息，使 Actor 学习到的更接近下采样图像修正，而不是针对编码器调整原始纹理。Random Crop 则直接从 1080p 原始帧中裁剪出 960 × 540 区域，在保持训练分辨率和显存开销不变的同时保留局部高频结构，使状态、动作与奖励之间的一致性更强。这也是完整模型能够最终取得平均 -9.48% BD-LPIPS 收益的重要前提。

表 4.9 训练策略对比与机制分析

训练策略	高频保持	状态一致性	说明
2× 下采样到 540p	差	中	易引入插值平滑, 弱化真实纹理
Random Crop 到 540p	好	高	保留局部细节, 更贴近真实编码输入

4.6 本章小结

本章按照实验环境与评价体系、综合率失真性能与效率分析、强化学习训练演进与案例诊断、增强机理与主观效果解释、系统消融实验与参数寻优的顺序，对本文方案进行了完整验证。实验结果表明，RAPNet 在 5 个 1080p 测试序列上取得平均 -9.48% 的 BD-LPIPS 收益，其中 ParkScene 和 BasketballDrive 分别达到 -13.45% 和 -12.84%；与此同时，模型参数量仅为 113K，前处理开销为 5.4ms/帧，占端到端时延的约 12%，表明该方案在真实 NVENC 编码链路中具有明确的工程可行性。

训练演进分析进一步说明，强化学习性能不仅取决于网络结构和损失函数，还高度依赖于环境定义是否与真实编码统计保持一致。频域与主观分析则表明，模型主要通过增强水平与垂直结构分量、抑制非结构化高频纹理来改善硬件编

码行为。最后，系统消融实验验证了两项关键设计：非边缘高频抑制损失决定了最终率失真收益的上限，**Random Crop** 训练策略则保证了状态分布与真实编码目标之间的一致性。

5 总结与展望

5.1 工作总结

本文围绕实时约束下的可部署视频编码优化这一目标，研究了强化学习前处理与 NVENC 硬件编码器的协同机制。主要工作总结如下：

(1) 提出了一套包含前处理与后处理概念位的混合编码框架。本文重点对 NVENC 硬件编码前处理模块进行了实证验证，将不可导的闭源硬件编码器纳入优化回路，实现了前处理模型对编码器特性的感知与预补偿；

(2) 引入了基于 Actor-Critic 架构的 RAPNet 前处理网络，采用残差学习策略将动作空间约束为对原始帧的微调修正，并设计了基于相对率失真增益的复合奖励函数，使策略能够在质量与码率之间进行内容相关的自适应权衡；

(3) 提出了包含加权 MSE 损失、非边缘高频抑制损失和全变分平滑损失的频域感知复合损失策略，用于抑制增强过程中的高频伪影并提升输出稳定性；

(4) 在 5 个 UVG 测试序列上，本文方法取得平均 -9.48% 的 BD-LPIPS 收益，其中 ParkScene 和 BasketballDrive 分别达到 -13.45% 与 -12.84%；该平均值为 5 个序列级 BD-LPIPS 结果的算术平均。在复杂度方面，模型参数量为 113K、平均单帧推理时延为 5.4ms，前处理开销约占端到端时延的 12%。这意味着在本文采用的 NVENC 实时编码链路中，额外引入 5.4ms/帧前处理后，能够换取可测的感知率失真收益。

5.2 研究局限性与讨论

在研究与评测过程中，本文也认识到当前方案在理论与工程实践上存在若干局限性，在此作补充讨论，以期后续研究提供更严谨的视角：

(1) **强化学习与监督学习的权衡：** 本文在早期将 RPP 监督学习方案迁移至 NVENC 链路时遭遇失败，由此转向强化学习框架。这一转变源于工程实验中的定性观察：第三章已展示，RPP 在本任务中出现了纹理发糊、平滑信号触发硬件码率控制误判等现象，说明仅依据重建或感知损失进行监督优化，未必能够稳定适配真实硬件编码器的反馈特性。因此，本文后续采用将 NVENC 视为黑盒环境的强化学习方案。上述讨论旨在说明本文方法路线的形成依据，而非对强化学习与监督学习作出一般性的优劣判定。

(2) **客观评价指标的选取与权衡：** 本文在主要结果评测中着重汇报了 LPIPS

/BD-LPIPS，而非传统的 PSNR。这是因为在低码率对应的 CQP 测试区间（ $QP \in \{37, 40, 42, 45, 47\}$ ）内，重建画面通常伴随严重的块效应和振铃伪影。传统基于像素误差的 PSNR 往往对平滑但丧失纹理的画面给出高分，与人眼主观感知严重背离；而基于深度特征提取的 LPIPS 对结构失真和高频伪影有着更准确的惩罚机制，更能反映真实观感。

(3) **数据规模与外推的局限性：**当前系统仅使用 5 个 UVG 测试序列（1080p）进行了定量验证。虽然这类测试序列在课题研究中具有代表性，且覆盖了平坦、快速运动、复杂纹理等典型场景，但这毕竟属于中小规模评测。当前结论主要建立在针对 HEVC 编码、1080p 分辨率与特定帧率的实时工程场景下。若要将结论外推至 4K/8K 超高清、非自然生成视频（如游戏录屏）或其他硬件平台，仍需更大规模的数据集与多样化编码器的进一步实验验证。

5.3 未来工作展望

尽管本文已在既定实验条件下验证了所提方案的有效性，但受限于本科阶段可获取的计算资源、可覆盖的数据规模与硬件平台多样性，以及接入真实业务系统的工程条件，仍有若干更具系统性的工作尚未充分展开。后续研究可重点围绕以下三个方向推进：

(1) **更大规模与多分辨率的数据验证：**当前实验主要基于 1080p 标准测试序列展开，能够支持方法有效性的初步论证，但对更广泛内容分布的覆盖仍然有限。若要进一步扩展到 2K、4K 乃至更复杂的动态场景，需要构建规模更大的训练与测试集，并完成大量离线编码与指标统计，对 GPU 算力、存储空间和实验周期均有较高要求，已超出当前毕业设计阶段的可承受范围。后续可在计算资源条件改善后，系统开展多分辨率、多内容类型的全面验证；

(2) **跨编码器与跨硬件平台的泛化评估：**本文工作主要围绕 NVENC 实时编码链路展开，结论目前仍建立在特定硬件平台与码率控制机制之上。若要将方法进一步推广到 VVC、AV1 或不同厂商的硬件编码器，除需重新适配实验链路外，还须长期稳定获取多种 GPU、移动端 SoC 及专用编解码设备。受当前平台条件限制，本文尚不具备开展大范围异构平台对比实验的基础，后续可在多平台设备条件具备时，系统评估该方法的跨平台迁移能力与泛化边界；

(3) **面向真实系统的端到端部署研究：**离线实验已表明前处理模块能够带来稳定的感知质量收益，但将其集成至实际视频通信或流媒体系统，还需在真实

业务链路中考察端到端时延、显存占用与长期运行稳定性。后续若具备相应的工程环境与合作条件，可进一步开展真实场景下的部署验证与系统级联合优化；同时，也可探索引入 CLIP 等大规模视觉语义模型^[41]，构建更高层次的语义一致性感知评价或辅助优化机制。

参考文献

- [1] SULLIVAN G J, OHM J R, HAN W J, et al. Overview of the high efficiency video coding (HEVC) standard[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2012, 22(12): 1649-1668.
- [2] BROSS B, WANG Y K, YE Y, et al. Overview of the versatile video coding (VVC) standard and its applications[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 31(10): 3736-3764.
- [3] LU G, OUYANG W, XU D, et al. DVC: An end-to-end deep video compression framework[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 11006-11015.
- [4] DING D, MA Z, CHEN D, et al. Advances in video compression system using deep neural network: A review and case studies[J/OL]. Proceedings of the IEEE, 2021, 109(9): 1494-1520. DOI: 10.1109/JPROC.2021.3059994.
- [5] LIANG J, CAO J, FAN Y, et al. VRT: A video restoration transformer[J/OL]. IEEE Transactions on Image Processing, 2024, 33: 2171-2182. DOI: 10.1109/TIP.2024.3372454.
- [6] LIANG J, FAN Y, XIANG X, et al. Recurrent video restoration transformer with guided deformable attention[C]//Advances in Neural Information Processing Systems 35 (NeurIPS 2022). 2022.
- [7] 陈彤, 陆明, 石俊奇, 等. 端到端智能图像视频编码的发展回顾与前沿展望[J/OL]. 中国图象图形学报, 2026: 1-23. DOI: 10.11834/jig.250627.
- [8] MA C, WU Z, CAI C, et al. Rate-perception optimized preprocessing for video coding[EB/OL]. 2023[2026-03-15]. <https://arxiv.org/abs/2301.10455>. DOI: 10.48550/arXiv.2301.10455.
- [9] LI J, LI B, LU Y. Deep contextual video compression[J]. Advances in Neural Information Processing Systems, 2021, 34: 18114-18125.
- [10] CONG W, KONG Y, LU M, et al. Integrating adaptive sampling for optimal learned video compression[C/OL]//ICASSP 2025 – IEEE International Conference on Acoustics, Speech and Signal Processing. 2025: 1-5. DOI: 10.1109/IC

- ASSP49660.2025.10888457.
- [11] SHEN M, XUE P, WANG C. Down-sampling based video coding using super-resolution technique[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2011, 21(6): 755-765.
 - [12] VANAM R, SETHURAMAN S. Encoder-aware motion compensated temporal filtering for video compression[C/OL]//Proc. SPIE 12674, Applications of Digital Image Processing XLVI. 2023. DOI: 10.1117/12.2681958.
 - [13] VANAM R, SETHURAMAN S. Improving compression efficiency using an encoder-aware motion compensated temporal filter[C/OL]//2023 Data Compression Conference (DCC). 2023: 367. DOI: 10.1109/DCC55655.2023.00085.
 - [14] CHAN K C K, WANG X, YU K, et al. BasicVSR: The search for essential components in video super-resolution and beyond[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 4947-4956.
 - [15] LIN H, HE X, QING L, et al. Improved low-bitrate HEVC video coding using deep learning based super-resolution and adaptive block patching[J]. IEEE Transactions on Multimedia, 2019, 21(12): 3010-3023.
 - [16] CHEN L C, HU J H, PENG W H. Reinforcement learning for HEVC/H.265 frame-level bit allocation[C/OL]//2018 IEEE 23rd International Conference on Digital Signal Processing (DSP). 2018: 1-5. DOI: 10.1109/ICDSP.2018.8631541.
 - [17] CHEN K, CHEN J, ZENG H, et al. Fast-MFQE: A fast approach for multi-frame quality enhancement on compressed video[J/OL]. Sensors, 2023, 23(16): 7227. DOI: 10.3390/s23167227.
 - [18] XU C, WU Y, YANG X, et al. LLM.265: Video codecs are secretly tensor codecs [C/OL]//MICRO '25: Proceedings of the 58th IEEE/ACM International Symposium on Microarchitecture. 2025: 445-460. DOI: 10.1145/3725843.3756078.
 - [19] ZHAO Y, FU Y, LIAO S, et al. A reinforcement learning based preprocessing filtering tool: AVS M9322[R]. AVS Working Group, 2025.
 - [20] MERCAT A, VIITANEN M, VANNE J. UVG dataset: 50/120fps 4K sequences for video codec analysis and development[C]//Proc. ACM Multimedia Systems Conference. Istanbul, Turkey, 2020.

- [21] BADAWEY W. Evolution and future directions of video coding standards and emerging compression technologies[J/OL]. Multimedia Tools and Applications, 2025, 84(41): 49607-49634. DOI: 10.1007/s11042-025-21108-2.
- [22] ZHANG K, ZUO W, CHEN Y, et al. Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising[J/OL]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155. DOI: 10.1109/TIP.2017.2662206.
- [23] HO M M, ZHOU J, HE G. RR-DnCNN v2.0: Enhanced restoration-reconstruction deep neural network for down-sampling-based video coding[J]. IEEE Transactions on Image Processing, 2021, 30: 1702-1715.
- [24] WANG W, WANG J, DING D, et al. ELIM: Extremely low-complexity implicit neural model for super resolution-based coding[C]//2024 Picture Coding Symposium (PCS). 2024: 1-5.
- [25] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [26] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [27] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017.
- [28] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[EB/OL]. 2018[2026-03-15]. <https://openai.com/index/language-unsupervised/>.
- [29] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.
- [30] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.
- [31] HE K, CHEN X, XIE S, et al. Masked autoencoders are scalable vision learners

- [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 16000-16009.
- [32] KARPATY A, TODERICI G, SHETTY S, et al. Large-scale video classification with convolutional neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 1725-1732.
- [33] SIMONYAN K, ZISSERMAN A. Two-stream convolutional networks for action recognition in videos[C]//Advances in Neural Information Processing Systems 27 (NIPS 2014). 2014: 568-576.
- [34] BERTASIUS G, WANG H, TORRESANI L. Is space-time attention all you need for video understanding?[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 813-824.
- [35] LIANG J, CAO J, SUN G, et al. SwinIR: Image restoration using swin transformer [C]//2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). IEEE, 2021: 1833-1844.
- [36] HUANG Y, CHEN J. Improved EDVR model for robust and efficient video super-resolution[C/OL]//2022 IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW). 2022: 103-111. DOI: 10.1109/WACVW54805.2022.00016.
- [37] WANG X, XIE L, YU K, et al. BasicSR: Open source image and video restoration toolbox[M/OL]. [S.l.]: GitHub, 2022[2026-03-15]. <https://github.com/XPixelGroup/BasicSR>.
- [38] GUO H, GUO Y, ZHA Y, et al. MambaIRv2: Attentive state space restoration [EB/OL]. 2024[2026-03-15]. <https://arxiv.org/abs/2411.15269>. DOI: 10.48550/arXiv.2411.15269.
- [39] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//Proceedings of the 3rd International Conference on Learning Representations (ICLR 2015). 2015.
- [40] LIU X Y, LI Z, ZHU M, et al. ElegantRL: Massively parallel framework for cloud-native deep reinforcement learning[M/OL]. [S.l.]: GitHub, 2021[2026-03-15]. <https://github.com/AI4Finance-Foundation/ElegantRL>.

- [41] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. 2021.

致 谢

若要追溯这四年的源头，文字便显得苍白，因为它承载不动珞珈山的一草一木。四载春秋，不过是山间草木荣枯了四回，而我的珞珈时光也即将画下句点。回望来时路，我仿佛仍是那个刚踏入牌坊、满怀憧憬的十八岁少年，却在不经意间，已长成了他人眼中步履沉稳的学长。从青涩到成熟，每一步成长都烙印在那些起伏的坡路上。

珞珈四载，是我生命里最华美的篇章。我永远不会忘记我遇到的每一个真挚的朋友，以及陪我打过一个又一个竞赛、一起砥砺前行队友和人生挚友。那些所有的失落和疲惫，因为有了你们，都碎成了漫天星光。珞珈山的坡路总是起伏，正如我们这些年的跌宕。但幸好，每一个上坡时的气喘吁吁，都有人并肩；每一个下坡时的如履平地，都有人共赏。我还记得每一次说走就走的旅行，那是我至今为止生命中最美好的几个瞬间，特别感谢有你们。此去经年，愿我们在没有彼此的江湖里，依然保留着珞珈山吹过的风。

“欲买桂花同载酒，终不似，少年游。”无论未来身在何方，这份独属于珞珈的意气与温情，都将是 我一生翻阅不尽的底色。

学海无涯，师恩难忘。诚挚感谢电子信息学院各位老师四年来的辛勤培养，感谢黄公平教授对我论文的悉心指导，感谢马展教授与陆明老师在我毕设选题及研究过程中给予的大力支持。实验室学长与同门的研讨协作，是我科研路上最坚实的后盾。

感谢我的父亲和母亲，支持我所做的一切决定，让我能放心地不遗余力去追寻自己的未来。

最后，感谢武汉大学，我最亲爱的母校。我永远不会忘记在武大的这段时光，珞珈山下，樱花树旁，是我青春最美的注脚。愿此去经年，无论走过多远的山海，我都是那个赤诚、热烈、永远向上的珞珈少年。

附录 A 关键实现说明

由于完整工程代码体量较大，且包含训练脚本、模型定义、编码调用与评估工具等多个部分，为避免影响论文主体的连贯性，本文仅在附录中给出核心模块的详细结构、伪代码、主要参数配置及关键运行命令。完整代码作为毕业设计附件单独提交。

A1 RAPNet (Actor) 详细网络结构

RAPNet 采用“Pixel Unshuffle $\rightarrow$ 残差卷积 $\rightarrow$ Pixel Shuffle”的三段式架构，在低分辨率特征空间完成残差增强后映射回原分辨率。各层的具体参数如表 A.1 所示。

表 A.1 RAPNet (Actor) 网络结构详情（scale = 2 时， $C_{in} = 3 \times 2^2 = 12$ ）

阶段	层名称	输入 $\rightarrow$ 输出通道	核/步长/填充	激活
色度上采样	upsample_chroma	$(1, H/2, W/2) \rightarrow (1, H, W)$	Bilinear $\times 2$	—
空间折叠	PixelUnshuffle(2)	$(3, H, W) \rightarrow (12, H/2, W/2)$	—	—
主干入口	head (Conv2d)	$12 \rightarrow 16$	$3 \times 3 / 1 / 1$	LeakyReLU(0.1)
残差体 $\times 5$	body[i].conv1	$16 \rightarrow 16$	$3 \times 3 / 1 / 1$	LeakyReLU(0.1)
	body[i].conv2	$16 \rightarrow 16$	$3 \times 3 / 1 / 1$	残差连接
主干出口	tail (Conv2d)	$16 \rightarrow 12$	$3 \times 3 / 1 / 1$	—
空间展开	PixelShuffle(2)	$(12, H/2, W/2) \rightarrow (3, H, W)$	—	—
残差限幅	$\delta = \tanh(\cdot) \times 0.05$	—	—	Tanh
色度均值归零	$\delta_{Cb/Cr} -= \text{mean}(\delta_{Cb/Cr})$	—	—	—
色度下采样	downsample_chroma	$(1, H, W) \rightarrow (1, H/2, W/2)$	Bilinear $\times 0.5$	—

总参数量约 113K。其中 5 个 ResBlock 贡献了主要参数量（每个 ResBlock 含两层 $16 \rightarrow 16$ 的 Conv2d，参数 $2 \times (16 \times 16 \times 3 \times 3 + 16) = 4640$ ，五个共 23200），head/tail 的 $12 \leftrightarrow 16$ 通道转换各贡献约 1744/1740 参数。

A2 ValueNet (Critic) 详细网络结构

ValueNet 采用双分支对称结构，分别对原始帧（状态 s ）和增强帧（动作 a ）提取特征，拼接后进行融合，最终输出标量 Q 值。各层的具体参数如表 A.2 所示。

表 A.2 ValueNet (Critic) 网络结构详情

阶段	层名称	输入 $\rightarrow$ 输出通道	核/步长/填充	激活
输入分支	branch_in.conv1	$3 \rightarrow 32$	$3 \times 3 / 1 / 1$	LeakyReLU(0.1)
	branch_in.conv2	$32 \rightarrow 32$	$3 \times 3 / 1 / 1$	—
输出分支	branch_out.conv1	$3 \rightarrow 32$	$3 \times 3 / 1 / 1$	LeakyReLU(0.1)
	branch_out.conv2	$32 \rightarrow 32$	$3 \times 3 / 1 / 1$	—
特征拼接	cat(in, out)	$32 + 32 = 64$	—	—
融合卷积	fusion_conv	$64 \rightarrow 64$	$3 \times 3 / 1 / 1$	LeakyReLU(0.1)
全局池化	AdaptiveAvgPool2d(1)	$(64, H, W) \rightarrow (64, 1, 1)$	—	—
时间平均	mean($\cdot$, dim = T)	$(B, T, 64) \rightarrow (B, 64)$	—	—
MLP 头	head.fc1	$64 \rightarrow 64$	—	ReLU
	head.fc2	$64 \rightarrow 1$	—	—

A3 损失权重与训练超参数

模型在 DDPG 风格的 Actor-Critic 训练框架中使用的完整超参数配置如表 A.3 所示。这些参数源自最终收敛版本（v44），此前经历了近 50 个版本的迭代调参。

表 A.3 训练主要超参数配置

类别	超参数	设定值
迭代与数据	训练总迭代次数	20 000
	每次采样帧数 (clip_len)	16
	输入分辨率	1920×1080
	Random Crop 裁剪尺寸	960×540
学习率	Actor 学习率 η_{Actor}	1×10^{-5}
	Critic 学习率 η_{Critic}	2×10^{-5}
	学习率衰减步长	每 1000 iter
	学习率衰减因子 γ_{lr}	1/3
奖励函数	质量权重 α	200
	码率权重 β	100
	QP 测试点集 $\mathcal{Q}$	{37, 40, 42, 45, 47}
	MSE 结构损失 w_{mse}	5

Actor 损失权重

续下页

表 A.3 训练主要超参数配置 (续)

类别	超参数	设定值
	非边缘高频抑制 w_{hf}	10
	TV 平滑损失 w_{TV}	0.1
残差限幅	Tanh 缩放系数	0.05 (即 $\pm 5\%$)
	Cb/Cr 通道	零均值约束
硬件分配	Actor	GPU 0 (cuda:0)
	Critic	GPU 1 (cuda:1)

A4 FFmpeg 编码/解码命令示例

训练环路中的编码与解码通过 Python subprocess 调用 FFmpeg 完成。以下是从代码中提取的典型 FFmpeg 命令结构:

编码命令 (NVENC HEVC 硬件编码, 恒定 QP 模式):

```

1 ffmpeg -y \
2   -f rawvideo -pix_fmt yuv420p \
3   -s:v 960x540 -r 120 \
4   -i input_crop.yuv \
5   -c:v hevc_nvenc \
6   -rc constqp -qp 42 \
7   -preset p4 -profile:v main \
8   -pix_fmt yuv420p \
9   output.hevc

```

解码命令 (HEVC $\rightarrow$ 原始 YUV420):

```

1 ffmpeg -y \
2   -i output.hevc \
3   -f rawvideo -pix_fmt yuv420p \
4   decoded.yuv

```

其中, `-rc constqp` 表示恒定 QP 码率控制模式 (训练阶段遍历 $Q = \{37, 40, 42, 45, 47\}$ 共 5 个 QP 点取平均奖励), `-preset p4` 对应 NVENC 的 Medium 编码预设, `-r 120` 为训练序列原始帧率。

A5 核心代码文件目录说明

项目工程的主要代码文件组织结构如下:

```

1 C0dec/
2 +-- data/
3 |   +-- rapnet_hevc_ppo_qp_yuv_1080p_v2.py
4 |   |   # 强化学习主训练脚本
5 |   |   # 包含: RAPNetYCbCr (Actor),
6 |   |   #           ValueNetYCbCrPair (Critic),
7 |   |   #           DeterministicActorCriticAgent,
8 |   |   #           HEVCNvencEnvironment,
9 |   |   #           train_loop()
10 |   +-- eval_rapnet_comprehensive.py
11 |   |   # BD-LPIPS/BD-Rate 综合评估脚本
12 |   +-- generate_baseline_rd.py
13 |   |   # 基线RD曲线生成工具
14 |   +-- run_ablation_3variants.py
15 |   |   # 消融实验自动化执行脚本
16 +-- test_sequences/
17 |   +-- Kimono1_1920x1080_24fps.yuv
18 |   +-- BQTerrace_1920x1080_60fps.yuv
19 |   +-- BasketballDrive_1920x1080_50fps.yuv
20 |   +-- Cactus_1920x1080_50fps.yuv
21 |   +-- ParkScene_1920x1080_24fps.yuv
22 +-- checkpoints/
23 |   +-- actor_iter*.pth      # Actor模型权重
24 |   +-- critic_iter*.pth    # Critic模型权重
25 +-- requirements.txt        # Python依赖包
    
```

附录 B 代码提交说明

本课题相关代码包括模型训练代码(`rapnet_hevc_ppo_qp_yuv_1080p_v2.py`)、推理与评估脚本(`eval_rapnet_comprehensive.py`)、FFmpeg 编码调用脚本及实验结果统计脚本。完整工程已随毕业设计材料一并提交, 论文正文与附录主要用于说明关键实现思路与核心流程。

如需复现实验结果, 请确保以下环境配置:

- NVIDIA GPU $\times 2$ (推荐 RTX 4090 或同等级别, 显存 $\geq 16\text{GB}$)
- CUDA 12.x + cuDNN 9.x
- Python 3.10+, PyTorch 2.0+
- FFmpeg 6.0+ (需包含 `hevc_nvenc` 编码器支持)
- 关键 Python 包: `lpips`, `tensorboard`, `numpy`, `opencv-python`

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统(CALIS)、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交 ☐ 当年 / ☐ 一年 / ☐ 两年 / ☐ 三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。（保密论文解密后遵守此规定）

论文作者（签名）：_____

学号：_____

学院：_____

日期： 年 月 日